

Simulations géostatistiques de variable continue

Ce chapitre présente les principes et les applications des simulations géostatistiques pour la modélisation de variables spatiales continues. Leur principal intérêt réside dans leur capacité à quantifier l'incertitude et à produire des représentations spatiales qui reproduisent la variabilité observée dans les données de terrain. La distinction entre estimation et simulation est d'abord établie, puis les cas conditionnel et non conditionnel sont détaillés. Les principaux algorithmes, notamment la décomposition de Cholesky et la simulation gaussienne séquentielle, sont ensuite présentés. Le chapitre expose également les critères guidant le choix de la méthode la mieux adaptée au contexte étudié et souligne les limites propres à chaque approche.

Table des matieres

12.1	Notations et hypothèses	3
12.1.1	Problématique du câble sous-marin (Alfaro, 1979)	3
12.1.2	Estimation ou simulation	5
12.2	Simulation non conditionnelle d'une variable continue	6
12.2.1	Méthode de simulation matricielle (décomposition de Cholesky)	7
12.2.1.1	Principe	7
12.2.1.2	Validation de la méthode	9
12.2.1.3	Limitations	9
12.2.1.4	Extensions	9
12.2.2	Cas des variables non gaussiennes : l'anamorphose	9
12.2.3	Passage à la simulation conditionnelle	9
	Atelier interactif 12.1 — Reproduction du variogramme	11
12.3	Simulation conditionnelle d'une variable continue	11
12.3.1	Méthode de simulation matricielle conditionnelle par décomposition de Cholesky	11
12.3.1.1	Choix des points	11
12.3.1.2	Principe	12
12.3.1.3	Validation de la méthode	14
12.3.1.4	Efficacité computationnelle	14
12.3.1.5	Limitations	15
12.3.2	Méthode de simulation séquentielle gaussienne (SGS)	15
12.3.2.1	Principe général	15
12.3.2.2	Algorithme	15
12.3.2.3	Validation théorique	16

12.3.2.4	Remarques importantes	17
12.3.3	Comparaison des deux méthodes	17
12.3.4	Méthode de recuit simulé	17
12.3.4.1	Principe général	18
12.3.4.2	Algorithme	18
12.3.4.3	Remarques	18
Atelier interactif 12.2 — Animation SGS		19
12.4	Post-conditionnement par krigeage simple (ou ordinaire)	19
12.4.1	Principe du post-conditionnement par krigeage	19
12.4.2	Propriétés mathématiques	20
12.5	Propriétés des simulations	21
Atelier interactif 12.3 — Non conditionnel ou conditionnel		22
Atelier interactif 12.4 — Site contaminé : krigeage ou simulations		23
Atelier interactif 12.5 — Ressources minières : krigeage ou simulations		23
12.6	Méthodes de simulation avancées	23
12.6.1	Bandes tournantes	24
12.6.2	Bandes tournantes spectrales	25
12.6.3	FFT-MA	26
12.6.4	Décomposition de Karhunen–Loève	26
12.6.5	Comparaison	27

! Objectifs d'apprentissage

À la fin de ce chapitre, vous serez en mesure de :

- Identifier les problèmes pour lesquels les méthodes de simulation géostatistique sont appropriées ;
- Distinguer les concepts d'estimation et de simulation, ainsi que leurs objectifs respectifs ;
- Expliquer les différences entre les simulations non conditionnelles et conditionnelles ;
- Appliquer les méthodes de simulation de Cholesky et de simulation séquentielle gaussienne (SGS), et en discuter les avantages et les limites ;
- Utiliser et interpréter les résultats de simulations dans le cadre de l'estimation des ressources ;
- Expliquer les principales propriétés statistiques et spatiales des simulations.

i Références

Ce chapitre s'appuie principalement sur les ouvrages suivants :

Lantuéjoul, C. (2002). *Geostatistical Simulation : Models and Algorithms*. Springer.
 Chilès, J., & Delfiner, P. (2012). *Geostatistics : Modeling Spatial Uncertainty*. John Wiley & Sons.

12.1 Notations et hypothèses

On modélise la variable régionalisée par un champ stochastique $Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}$ défini sur un domaine $\mathcal{D} \subset \mathbb{R}^n$. Le krigeage et la simulation géostatistique reposent sur ce même modèle spatial, mais répondent à des objectifs différents : le krigeage cherche une estimation optimale, tandis que la simulation génère plusieurs configurations possibles du champ conditionnellement aux données.

12.1.1 Problématique du câble sous-marin (Alfaro, 1979)

L'exemple proposé par Alfaro (1979) illustre directement cette distinction. Supposons que l'on cherche à estimer la longueur d'un câble posé sur le fond marin à partir de données bathymétriques mesurées tous les 100, m le long d'un profil.

Une première approche consiste à kriger la profondeur entre les observations, puis à calculer la longueur de la courbe estimée. On obtient alors :

$$L_{\text{krigeage}} = 945, \text{ m.}$$

Un levé beaucoup plus dense, réalisé tous les 10, m, révèle toutefois une longueur de :

$$L_{\text{réelle}} = 1182, \text{ m.}$$

Cet écart résulte du lissage produit par le krigeage. Les variations de petite échelle et les valeurs extrêmes sont atténuées, de sorte que le profil estimé est plus régulier et, dans ce cas, artificiellement plus court. La longueur étant une fonctionnelle non linéaire du profil, elle ne peut généralement pas être évaluée correctement à partir de la seule estimation krigée.

La simulation conditionnelle propose une autre approche. Après avoir modélisé la loi marginale et la continuité spatiale de $Z(\mathbf{x})$, on génère plusieurs profils compatibles avec les observations et avec le modèle géostatistique. Chaque réalisation présente des détails différents entre les points mesurés, tout en demeurant plausible compte tenu des données disponibles.

La longueur est calculée séparément sur chaque réalisation :

$$L^{(s)} = L(Z^{(s)}),$$

puis son espérance conditionnelle est estimée par la moyenne des résultats :

$$\mathbb{E}[L \mid \mathcal{D}] \approx \frac{1}{S} \sum_{s=1}^S L(Z^{(s)}),$$

où $\mathcal{D}$ représente les données observées. La dispersion des valeurs $L^{(s)}$ permet également de quantifier l'incertitude associée à la longueur du câble.




FIGURE 1 : Problématique du câble sous-marin (Alfaro, 1979). (a) Données bathymétriques et profil réel, (b) profil estimé par krigeage, (c) une réalisation simulée conditionnelle, (d) ensemble de simulations conditionnelles illustrant l'incertitude spatiale.

12.1.2 Estimation ou simulation

En estimation, la valeur krigée au point $\mathbf{x}_0$ est une combinaison linéaire des observations :

$$Z^*(\mathbf{x}_0) = \sum_i \lambda_i Z(\mathbf{x}_i).$$

Les poids sont déterminés de manière à minimiser la variance de l'erreur sous les contraintes propres au type de krigeage utilisé. Le résultat constitue le meilleur prédicteur linéaire sans biais, ou BLUP. Dans un cadre multigaussien avec moyenne connue, le krigeage simple coïncide avec l'espérance conditionnelle :

$$\mathbb{E}[Z(\mathbf{x}_0) \mid Z(\mathbf{x}_1), \dots, Z(\mathbf{x}_n)]. \quad (1)$$

Cette moyenne conditionnelle fournit une estimation ponctuelle optimale, mais elle ne représente pas toute la distribution conditionnelle. Les valeurs extrêmes sont atténuées et la variabilité spatiale de la carte krigée est inférieure à celle du champ modélisé.

En simulation conditionnelle, une réalisation est plutôt tirée de la distribution du champ sachant les observations :

$$Z^{(s)}(\mathbf{x}) \sim p(Z(\mathbf{x}) \mid Z(\mathbf{x}_1), \dots, Z(\mathbf{x}_n)). \quad (2)$$

Les réalisations ne cherchent pas à minimiser l'erreur en chaque point. Elles représentent différents scénarios possibles entre les observations. Considérées collectivement, elles reproduisent la loi marginale et la structure de dépendance spatiale du modèle (Figure 2). En l'absence d'erreur de mesure, elles honorent également les valeurs observées aux points de conditionnement.




FIGURE 2 : Krigeage lissé vs réalisations conditionnelles : les réalisations reproduisent l'histogramme et le variogramme du modèle, contrairement au krigeage qui écrase la variance.

Pour un grand nombre de simulations indépendantes, leur moyenne ponctuelle converge vers la moyenne conditionnelle. Dans le cadre multigaussien du krigeage simple :

$$\lim_{S \rightarrow \infty} \frac{1}{S} \sum_{s=1}^S Z^{(s)}(\mathbf{x}) = Z_{SK}^*(\mathbf{x}) \quad (3)$$

Le krigeage simple est donc la « moyenne » de toutes les réalisations possibles, ce qui explique son caractère lissé. La relation est exacte pour le krigeage simple (moyenne connue), seulement approchée pour le krigeage ordinaire.

Le tableau suivant résume les propriétés comparées.

Propriété	Krigeage $Z^*(\mathbf{x})$	Simulation $Z^{(s)}(\mathbf{x})$
Objectif	Fournir une estimation ponctuelle optimale	Générer des scénarios plausibles
Variance spatiale	$\text{Var}[Z^*] < \text{Var}[Z]$ (sous-estimée)	$\text{Var}[Z^{(s)}] = \text{Var}[Z]$ (préservée)
Variogramme	Partiellement reproduit (lissage)	Intégralement reproduit
Conditionnement	Exact aux observations	Exact aux observations
Valeurs extrêmes	Atténuées	Préservées
Erreur ponctuelle	Minimale (variance de krigeage)	Plus élevée qu'une estimation
Fonctionnelles non linéaires	Biaisées (effet de lissage)	Non biaisées (sur la moyenne des réalisations)
Quantification d'incertitude	Variance de krigeage (locale)	Dispersion des réalisations (globale)
Nombre de résultats	Une seule estimation	Multiples scénarios équiprobables

Le choix dépend donc de la quantité recherchée. Le krigeage convient lorsque l'objectif principal est d'obtenir une estimation ponctuelle ou une carte moyenne. La simulation devient nécessaire lorsque l'on cherche à préserver l'hétérogénéité spatiale, à étudier la connectivité, à quantifier un risque ou à évaluer une fonctionnelle non linéaire, comme une longueur, un volume au-delà d'un seuil, un tonnage au-delà d'un seuil ou une réponse calculée par un modèle numérique.

Dans le cas du câble sous-marin (Figure 1), le krigeage produit un profil lissé qui sous-estime la longueur réelle ($L_{\text{krigeage}} = 945$ m contre $L_{\text{réel}} = 1182$ m), tandis que la moyenne sur plusieurs simulations conditionnelles fournit une estimation non biaisée de cette fonctionnelle non linéaire,

$$\mathbb{E}[L] \approx \frac{1}{S} \sum_{s=1}^S L(Z^{(s)}(\mathbf{x})), \quad (4)$$

où $L(\cdot)$ désigne la fonctionnelle longueur appliquée à chaque réalisation.

12.2 Simulation non conditionnelle d'une variable continue

La simulation non conditionnelle génère des réalisations d'un champ aléatoire $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$ sans imposer de contrainte aux points d'observation. Chaque réalisation respecte les propriétés statistiques du modèle soit le variogramme (ou covariance) et la loi marginale, mais ne passe pas forcément par les données mesurées.

Plusieurs méthodes s’y prêtent : méthodes matricielles (décomposition de Cholesky, LU), moyennes mobiles, bandes tournantes, méthodes autorégressives et méthodes fréquentielles (FFT-MA). Les bandes tournantes ramènent une simulation à n dimensions à des simulations 1D le long de droites, recombinaées par projection ; elles sont efficaces sur de grands domaines. Les méthodes fréquentielles, dont la FFT-MA (*Fast Fourier Transform — Moving Average*), simulent dans le domaine spectral et tirent parti de la transformée de Fourier rapide sur grille régulière. Ces méthodes sont détaillées à la section « Méthodes de simulation avancées » (voir plus loin dans ce chapitre) ; on renvoie aussi à Lantuéjoul (2002) et à Chilès et Delfiner (2012). On présente ici la méthode matricielle de décomposition de Cholesky, l’approche de référence pour les champs de taille modérée.

12.2.1 Méthode de simulation matricielle (décomposition de Cholesky)

La méthode de Cholesky permet de simuler les valeurs du champ sur un ensemble fini de positions. On choisit d’abord N points de simulation :

$$\mathcal{S} = \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N \subset \mathcal{D},$$

où $\mathcal{D} \subset \mathbb{R}^d$ est le domaine spatial. Ces positions peuvent correspondre aux nœuds d’une grille régulière, aux centres de cellules d’un modèle ou à un ensemble quelconque de points irrégulièrement répartis.

La réalisation du champ sur cet ensemble est représentée par le vecteur :

$$\mathbf{Z}_{\mathcal{S}} = [Z(\mathbf{x}_1), Z(\mathbf{x}_2), \dots, Z(\mathbf{x}_N)]^{\top}.$$

La simulation matricielle ne génère donc pas directement une fonction continue sur tout le domaine. Elle génère les valeurs de cette fonction aux positions de $\mathcal{S}$. La résolution spatiale de la réalisation dépend ainsi du nombre et de la disposition des points choisis.

Dans le cas d’un champ gaussien, on suppose :

$$\mathbf{Z}_{\mathcal{S}} \sim \mathcal{N}(\mathbf{m}, \mathbf{K}),$$

où $\mathbf{m}$ est le vecteur des moyennes aux points de simulation :

$$\mathbf{m} = [m(\mathbf{x}_1), m(\mathbf{x}_2), \dots, m(\mathbf{x}_N)]^{\top},$$

et $\mathbf{K}$ est leur matrice de covariance.

12.2.1.1 Principe

Soient n points à simuler pour un champ de covariance $C(h)$. On procède en trois étapes.

1. Construction de la matrice de covariance.

Pour chaque paire de positions $\mathbf{x}_i$ et $\mathbf{x}_j$, on calcule :

$$K_{ij} = \text{Cov} [Z(\mathbf{x}_i), Z(\mathbf{x}_j)] .$$

Sous l'hypothèse de stationnarité, cette covariance dépend uniquement du vecteur de séparation :

$$K_{ij} = C(\mathbf{x}_i - \mathbf{x}_j), \quad i, j = 1, \dots, N. \quad (5)$$

La matrice obtenue s'écrit :

$$\mathbf{K} = \begin{bmatrix} C(\mathbf{0}) & C(\mathbf{x}_1 - \mathbf{x}_2) & \cdots & C(\mathbf{x}_1 - \mathbf{x}_N) \\ C(\mathbf{x}_2 - \mathbf{x}_1) & C(\mathbf{0}) & \cdots & C(\mathbf{x}_2 - \mathbf{x}_N) \\ \vdots & \vdots & \ddots & \vdots \\ C(\mathbf{x}_N - \mathbf{x}_1) & C(\mathbf{x}_N - \mathbf{x}_2) & \cdots & C(\mathbf{0}) \end{bmatrix} .$$

Elle est symétrique et doit être définie positive pour permettre une décomposition de Cholesky standard.

2. Décomposition de Cholesky.

On factorise la matrice de covariance sous la forme :

$$\mathbf{K} = \mathbf{L}\mathbf{L}^\top, \quad (6)$$

où $\mathbf{L}$ est une matrice triangulaire inférieure.

3. Génération de la réalisation.

On génère un vecteur de N variables normales indépendantes :

$$\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N),$$

puis on construit la réalisation :

$$\mathbf{z}^{(s)} = \mathbf{m} + \mathbf{L}\mathbf{y}. \quad (7)$$

Lorsque le champ est supposé centré, $\mathbf{m} = \mathbf{0}$, cette expression devient simplement :

$$\mathbf{z}^{(s)} = \mathbf{L}\mathbf{y}.$$

Chaque composante $z_i^{(s)}$ représente la valeur simulée au point $\mathbf{x}_i$:

$$z_i^{(s)} = Z^{(s)}(\mathbf{x}_i).$$

12.2.1.2 Validation de la méthode

La réalisation a bien la covariance voulue :

$$\text{Cov}[\mathbf{z}] = \text{Cov}[\mathbf{L}\mathbf{y}] = \mathbf{L} \text{Cov}[\mathbf{y}] \mathbf{L}^\top = \mathbf{L} \mathbf{I} \mathbf{L}^\top = \mathbf{L} \mathbf{L}^\top = \mathbf{K} \quad (8)$$

Le vecteur $\mathbf{z}$ est donc une réalisation non conditionnelle du champ gaussien de covariance $C(h)$.

12.2.1.3 Limitations

- **Taille du problème.** Le coût de la décomposition de Cholesky croît en $\mathcal{O}(n^3)$. En pratique, la méthode tient jusqu'à $n \lesssim 10\,000$ points.
- **Matrice non singulière.** $\mathbf{K}$ doit être définie positive, ce qui interdit deux points exactement confondus.
- **Effet de pépité.** Un effet de pépité C_0 peut être intégré directement à la matrice de covariance en ajoutant C_0 à ses termes diagonaux. Si l'on souhaite distinguer explicitement la composante spatialement structurée du bruit non corrélé, on peut aussi simuler d'abord le champ structuré, puis ajouter un bruit blanc indépendant : $\varepsilon \sim \mathcal{N}(\mathbf{0}, C_0 \mathbf{I})$. La réalisation finale s'écrit alors : $\mathbf{z}^{(s)} = \mathbf{m} + \mathbf{L}\mathbf{y} + \varepsilon$.

12.2.1.4 Extensions

D'autres décompositions existent, notamment celle fondée sur les valeurs et vecteurs propres de $\mathbf{K}$ (décomposition spectrale), mais Cholesky reste la plus efficace quand elle s'applique.

12.2.2 Cas des variables non gaussiennes : l'anamorphose

La décomposition de Cholesky, comme la SGS vue plus loin, suppose la variable gaussienne. Or les teneurs minières le sont rarement : elles sont asymétriques, souvent proches d'une loi log-normale. On contourne la difficulté par une **anamorphose gaussienne**, une fonction monotone φ telle que

$$Z(\mathbf{x}) = \varphi(Y(\mathbf{x})), \quad (9)$$

où $Y(\mathbf{x})$ est un champ gaussien. On simule Y — toute la théorie du chapitre s'y applique — puis on transforme chaque réalisation par $Z = \varphi(Y)$ pour revenir à la variable d'origine (Figure 3). Le cas log-normal correspond à $Z = \exp(Y)$. En pratique, on estime φ à partir de l'histogramme des données, de sorte que les réalisations finales reproduisent la loi marginale observée. C'est cette transformation qui sous-tend le cas log-normal de l'atelier 12.4.

12.2.3 Passage à la simulation conditionnelle

Une réalisation non conditionnelle devient conditionnelle de deux façons : par post-conditionnement par krigeage (voir plus loin) ou en étendant directement la décomposition matricielle pour intégrer les observations (section suivante).




FIGURE 3 : Anamorphose gaussienne $z = \varphi(y)$ reliant le champ gaussien $Y \sim N(0,1)$ à la teneur brute Z .

Atelier interactif 12.1 — Reproduction du variogramme

Cet atelier interactif n'est disponible que dans la version web du chapitre.

12.3 Simulation conditionnelle d'une variable continue

La simulation conditionnelle génère des réalisations d'un champ aléatoire $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$ qui honorent les valeurs observées aux points d'échantillonnage. Considérées collectivement, les réalisations reproduisent la distribution conditionnelle définie par le modèle géostatistique, notamment sa covariance et sa loi marginale.

Cette reproduction exacte des observations suppose un conditionnement dur, sans erreur de mesure. Lorsque les données sont incertaines ou bruitées, le conditionnement doit être adapté afin de tenir compte de leur erreur.

Pour les champs gaussiens, plusieurs méthodes peuvent être utilisées : l'extension conditionnelle des méthodes matricielles, la simulation séquentielle gaussienne ou le post-conditionnement par krigeage d'une simulation non conditionnelle. Cette dernière approche peut notamment s'appliquer aux simulations produites par bandes tournantes, moyennes mobiles, méthodes spectrales ou développement de Karhunen–Loève.

On présente ici les deux approches fondamentales : la simulation matricielle conditionnelle par décomposition de Cholesky et la simulation séquentielle gaussienne.

12.3.1 Méthode de simulation matricielle conditionnelle par décomposition de Cholesky

La méthode prolonge directement la simulation matricielle non conditionnelle. Elle permet de simuler simultanément les valeurs du champ sur un ensemble fini de positions, tout en imposant les valeurs connues aux points de conditionnement.

12.3.1.1 Choix des points

On distingue deux ensembles de positions.

Les N_d points de conditionnement sont regroupés dans :

$$\mathcal{S}_d = \{\mathbf{x}_{d,1}, \dots, \mathbf{x}_{d,N_d}\}.$$

Les valeurs du champ y sont observées et regroupées dans le vecteur :

$$\mathbf{z}_d = [Z(\mathbf{x}_{d,1}), \dots, Z(\mathbf{x}_{d,N_d})]^\top.$$

Les N_s points auxquels le champ doit être simulé sont regroupés dans :

$$\mathcal{S}_s = \{\mathbf{x}_{s,1}, \dots, \mathbf{x}_{s,N_s}\}.$$

Le vecteur des valeurs inconnues à ces positions est noté :

$$\mathbf{Z}_s = [Z(\mathbf{x}_{s,1}), \dots, Z(\mathbf{x}_{s,N_s})]^\top.$$

Les positions de simulation peuvent correspondre aux nœuds d'une grille régulière, aux centres de cellules d'un modèle ou à un ensemble irrégulier de points.

12.3.1.2 Principe

Le vecteur regroupant les valeurs aux points de conditionnement et de simulation suit une distribution gaussienne jointe :

$$\begin{bmatrix} \mathbf{Z}_d \\ \mathbf{Z}_s \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{m}_d \\ \mathbf{m}_s \end{bmatrix}, \begin{bmatrix} \mathbf{K}_{dd} & \mathbf{K}_{ds} \\ \mathbf{K}_{sd} & \mathbf{K}_{ss} \end{bmatrix} \right),$$

où $\mathbf{m}_d$ et $\mathbf{m}_s$ sont les vecteurs des moyennes aux deux ensembles de points.

La simulation se déroule en cinq étapes.

1. **Construction de la matrice de covariance globale.** Pour chaque paire de positions, on calcule la covariance définie par le modèle spatial. La matrice globale s'écrit :

$$\mathbf{K} = \begin{bmatrix} \mathbf{K}_{dd} & \mathbf{K}_{ds} \\ \mathbf{K}_{sd} & \mathbf{K}_{ss} \end{bmatrix}, \quad (10)$$

avec :

- $\mathbf{K}_{dd}$, de taille $N_d \times N_d$, pour les covariances entre les points de conditionnement ;
- $\mathbf{K}_{ss}$, de taille $N_s \times N_s$, pour les covariances entre les points à simuler ;
- $\mathbf{K}_{ds} = \mathbf{K}_{sd}^\top$, pour les covariances croisées.

Sous l'hypothèse de stationnarité :

$$K_{ij} = C(\mathbf{x}_i - \mathbf{x}_j).$$

2. **Décomposition de Cholesky par blocs.** On factorise la matrice globale sous la forme :

$$\mathbf{K} = \mathbf{L}\mathbf{L}^\top,$$

avec :

$$\mathbf{L} = \begin{bmatrix} \mathbf{L}_{dd} & \mathbf{0} \\ \mathbf{L}_{sd} & \mathbf{L}_{ss} \end{bmatrix}.$$

On obtient donc :

$$\mathbf{K} = \begin{bmatrix} \mathbf{L}_{dd} & \mathbf{0} \\ \mathbf{L}_{sd} & \mathbf{L}_{ss} \end{bmatrix} \begin{bmatrix} \mathbf{L}_{dd}^\top & \mathbf{L}_{sd}^\top \\ \mathbf{0} & \mathbf{L}_{ss}^\top \end{bmatrix}. \quad (11)$$

Le bloc $\mathbf{L}_{dd}$ est associé aux points de conditionnement, tandis que $\mathbf{L}_{ss}$ représente la variabilité qui subsiste aux points à simuler après conditionnement.

3. **Détermination de la composante associée aux observations.** Dans la simulation non conditionnelle, le vecteur aux points de conditionnement s'écrirait :

$$\mathbf{Z}_d = \mathbf{m}_d + \mathbf{L}_{dd}\mathbf{y}_d.$$

Pour imposer les observations $\mathbf{Z}_d = \mathbf{z}_d$, on résout :

$$\mathbf{z}_d = \mathbf{m}_d + \mathbf{L}_{dd}\mathbf{y}_d.$$

On obtient :

$$\mathbf{y}_d = \mathbf{L}_{dd}^{-1} (\mathbf{z}_d - \mathbf{m}_d). \quad (12)$$

En pratique, ce système triangulaire est résolu directement, sans calculer explicitement l'inverse de $\mathbf{L}_{dd}$.

4. **Génération de la composante aléatoire.** On génère un vecteur de N_s variables normales indépendantes :

$$\mathbf{y}_s \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{N_s}).$$

Un nouveau vecteur $\mathbf{y}_s$ est généré pour chaque réalisation.

5. **Génération de la réalisation conditionnelle.** La réalisation complète s'écrit :

$$\begin{bmatrix} \mathbf{z}_d \\ \mathbf{z}_s^{(r)} \end{bmatrix} = \begin{bmatrix} \mathbf{m}_d \\ \mathbf{m}_s \end{bmatrix} + \begin{bmatrix} \mathbf{L}_{dd} & \mathbf{0} \\ \mathbf{L}_{sd} & \mathbf{L}_{ss} \end{bmatrix} \begin{bmatrix} \mathbf{y}_d \\ \mathbf{y}_s^{(r)} \end{bmatrix}. \quad (13)$$

La partie simulée est donc :

$$\mathbf{z}_s^{(r)} = \mathbf{m}_s + \mathbf{L}_{sd}\mathbf{y}_d + \mathbf{L}_{ss}\mathbf{y}_s^{(r)}. \quad (14)$$

En remplaçant $\mathbf{y}_d$ par son expression :

$$\mathbf{z}_s^{(r)} = \mathbf{m}_s + \mathbf{L}_{sd}\mathbf{L}_{dd}^{-1} (\mathbf{z}_d - \mathbf{m}_d) + \mathbf{L}_{ss}\mathbf{y}_s^{(r)}.$$

La réalisation conditionnelle se compose ainsi de deux parties : une moyenne conditionnelle déterminée par les observations et une composante aléatoire représentant l'incertitude résiduelle.

12.3.1.3 Validation de la méthode

La moyenne conditionnelle des valeurs simulées est :

$$\mathbb{E}[\mathbf{Z}_s \mid \mathbf{Z}_d = \mathbf{z}_d] = \mathbf{m}_s + \mathbf{L}_{sd} \mathbf{L}_{dd}^{-1} (\mathbf{z}_d - \mathbf{m}_d).$$

Les relations entre les blocs de la décomposition donnent :

$$\mathbf{L}_{sd} \mathbf{L}_{dd}^{-1} = \mathbf{K}_{sd} \mathbf{K}_{dd}^{-1}.$$

La moyenne conditionnelle devient donc :

$$\mathbf{m}_{s|d} = \mathbf{m}_s + \mathbf{K}_{sd} \mathbf{K}_{dd}^{-1} (\mathbf{z}_d - \mathbf{m}_d). \quad (15)$$

Cette expression correspond au krigeage simple simultané des valeurs aux points de simulation.

La covariance conditionnelle est :

$$\mathbf{K}_{s|d} = \mathbf{K}_{ss} - \mathbf{K}_{sd} \mathbf{K}_{dd}^{-1} \mathbf{K}_{ds}. \quad (16)$$

Elle correspond au complément de Schur de $\mathbf{K}_{dd}$ dans la matrice globale. La décomposition par blocs garantit également que :

$$\mathbf{L}_{ss} \mathbf{L}_{ss}^\top = \mathbf{K}_{s|d}.$$

La simulation conditionnelle peut donc être résumée par :

$$\mathbf{z}_s^{(r)} = \mathbf{m}_{s|d} + \mathbf{L}_{ss} \mathbf{y}_s^{(r)}.$$

Le premier terme est la moyenne conditionnelle commune à toutes les réalisations. Le second varie d'une réalisation à l'autre et restitue la covariance conditionnelle résiduelle.

12.3.1.4 Efficacité computationnelle

La décomposition de Cholesky et le calcul de la moyenne conditionnelle ne sont effectués qu'une seule fois. Pour générer M réalisations, on calcule d'abord :

$$\mathbf{m}_{s|d} = \mathbf{m}_s + \mathbf{L}_{sd} \mathbf{y}_d.$$

Pour chaque réalisation $r = 1, \dots, M$, on génère ensuite un nouveau vecteur $\mathbf{y}_s^{(r)}$ et on calcule :

$$\mathbf{z}_s^{(r)} = \mathbf{m}_{s|d} + \mathbf{L}_{ss} \mathbf{y}_s^{(r)}.$$

Le coût initial de la factorisation demeure élevé, mais sa réutilisation rend l'approche intéressante lorsqu'un grand nombre de réalisations doit être généré pour un ensemble fixe de points.

12.3.1.5 Limitations

- **Mémoire et temps de calcul.** La matrice globale contient $(N_d + N_s)^2$ termes et sa décomposition directe a un coût de l'ordre de $\mathcal{O}((N_d + N_s)^3)$. La méthode est donc réservée aux champs de taille modérée.
- **Matrice définie positive.** La matrice $\mathbf{K}$ doit être définie positive. Des points confondus, des modèles de covariance inadmissibles ou des problèmes de précision numérique peuvent empêcher la décomposition.
- **Conditionnement global.** Tous les points de conditionnement sont pris en compte simultanément. Cette propriété est avantageuse pour de petits ensembles, mais devient coûteuse lorsque le nombre de données est élevé.
- **Ensemble fixe de positions.** Toute modification des points de conditionnement ou des points de simulation exige généralement de reconstruire et de factoriser la matrice de covariance.

12.3.2 Méthode de simulation séquentielle gaussienne (SGS)

La SGS construit une réalisation conditionnelle point par point, en tirant chaque valeur de la loi conditionnelle donnée par le krigeage simple.

12.3.2.1 Principe général

L'algorithme visite chaque point à simuler et tire une valeur de la loi gaussienne conditionnelle à l'information déjà disponible (observations initiales et valeurs déjà simulées). Cette valeur devient aussitôt une nouvelle donnée conditionnante (Figure 4).




FIGURE 4 : Un pas de simulation séquentielle gaussienne : voisinage (données + valeurs déjà simulées) et loi gaussienne conditionnelle d'où l'on tire.

12.3.2.2 Algorithme

On dispose de N points conditionnants et on veut simuler n points inconnus.

1. **Chemin de simulation aléatoire.** On fixe un ordre de visite $\{\mathbf{x}_{\pi(1)}, \dots, \mathbf{x}_{\pi(n)}\}$. Cet ordre compte, car chaque valeur simulée pèse sur les suivantes.

2. **Parcours séquentiel.** Pour chaque point $\mathbf{x}_i$ selon le chemin :

- a) Sélectionner les données conditionnantes : les N observations initiales et les valeurs déjà simulées aux points précédents. En pratique, on se restreint à un voisinage mobile (les k points les plus proches) pour limiter le coût.
- b) Effectuer un krigeage simple au point $\mathbf{x}_i$ avec le modèle de covariance $C(h)$ (ou variogramme $\gamma(h)$). On obtient la moyenne conditionnelle $Z_i^* = \mathbb{E}[Z(\mathbf{x}_i) \mid \text{données connues}]$ et la variance conditionnelle $\sigma_{\text{SK}}^2(\mathbf{x}_i) = \text{Var}[Z(\mathbf{x}_i) \mid \text{données connues}]$.
- c) Tirer une valeur de la loi gaussienne conditionnelle :

$$Z(\mathbf{x}_i) \sim \mathcal{N}(Z_i^*, \sigma_{\text{SK}}^2(\mathbf{x}_i)). \quad (17)$$

- d) Ajouter la valeur simulée aux données conditionnantes pour la suite.

3. **Répéter** jusqu'à avoir visité tous les points du chemin.

12.3.2.3 Validation théorique

La SGS reproduit le variogramme cible, ce qu'on démontre par récurrence. Supposons que n points simulés aient la bonne structure spatiale (covariance $\mathbf{K}_{nn}$). Au point $n + 1$, la valeur krigée est

$$Z_{n+1}^* = \lambda^\top \mathbf{Z}_{ns}, \quad (18)$$

où $\lambda = \mathbf{K}_{nn}^{-1} \mathbf{K}_{n1}$ et $\mathbf{K}_{n1}$ est la covariance entre les n points déjà simulés et le point $n + 1$. La valeur simulée est

$$Z_{n+1} = Z_{n+1}^* + \varepsilon, \quad (19)$$

où $\varepsilon \sim \mathcal{N}(0, \sigma_{\text{SK}}^2)$ est indépendant de $\mathbf{Z}_{ns}$. La covariance avec les points précédents vaut

$$\text{Cov}[Z_{n+1}, \mathbf{Z}_{ns}] = \text{Cov}[\lambda^\top \mathbf{Z}_{ns}, \mathbf{Z}_{ns}] + \text{Cov}[\varepsilon, \mathbf{Z}_{ns}] = \lambda^\top \mathbf{K}_{nn} + \mathbf{0} = \mathbf{K}_{n1}^\top, \quad (20)$$

et la variance au point $n + 1$,

$$\text{Var}[Z_{n+1}] = \text{Var}[\lambda^\top \mathbf{Z}_{ns}] + \text{Var}[\varepsilon] = \lambda^\top \mathbf{K}_{nn} \lambda + \sigma_{\text{SK}}^2 = C(0). \quad (21)$$

Les $n + 1$ points ont donc bien la structure de covariance voulue.

La démonstration suppose un voisinage global : à chaque étape, le krigeage utilise toutes les données et toutes les valeurs déjà simulées, et la reproduction du variogramme est exacte. En pratique, on restreint le krigeage à un voisinage mobile (voir ci-dessous); la reproduction n'est plus qu'approchée. Le palier reste correct, mais le raccord aux distances intermédiaires est légèrement lissé.

12.3.2.4 Remarques importantes

Voisinage mobile. Pour ne pas alourdir les systèmes de krigeage, on se limite à une fenêtre locale. Les points éloignés pèsent peu (effet d'écran) et s'ignorent sans perte notable.

Effet de pépité. En non conditionnel, mieux vaut ajouter l'effet de pépité C_0 après la simulation, sous forme de bruit indépendant. En conditionnel, c'est impossible : les observations incluent déjà l'effet de pépité et doivent être reproduites exactement.

Chemin de simulation. Un parcours systématique peut créer des artefacts directionnels ; on recommande un ordre aléatoire. Pour améliorer la qualité, on procède par passes multi-échelles (grossier vers fin), qui capturent les structures à différentes échelles.

Généralité de la méthode. La normalité est commode (le krigeage simple donne exactement la loi conditionnelle), mais la démonstration ne repose que sur la linéarité du krigeage. On peut donc simuler un bruit ε non gaussien (moyenne nulle, variance σ_{SK}^2) : le variogramme sera respecté, mais l'histogramme tendra vers une forme plus gaussienne par le théorème central limite.

Extension multivariée. La SGS se combine facilement à la décomposition matricielle (LU) pour simuler plusieurs variables corrélées en de multiples points.

12.3.3 Comparaison des deux méthodes

Critère	Méthode matricielle	SGS
Taille maximale	$N + n \lesssim 10\,000$	Quasi illimitée (voisinage mobile)
Coût pour 1 réalisation	$\mathcal{O}((N + n)^3)$ (décomposition)	$\mathcal{O}(n \times k^3)$ avec k voisins
Coût pour M réalisations	Décomposition une fois, puis $\mathcal{O}(n)$ par réalisation	$\mathcal{O}(M \times n \times k^3)$
Voisinage mobile	Non	Oui
Effet de pépité	Traitement séparé recommandé	Inclus naturellement
Artefacts	Aucun	Possibles si chemin mal choisi
Flexibilité	Limitée	Haute (multi-échelle, multivariée)

En résumé, on choisit la méthode matricielle pour générer plusieurs réalisations sur des champs de taille modérée, et la SGS pour des grands domaines avec voisinage mobile, ou quand des contraintes complexes doivent être intégrées.

12.3.4 Méthode de recuit simulé

Le recuit simulé (*simulated annealing*) est une technique d'optimisation très souple, utile quand il faut reproduire, au-delà des moments d'ordre un et deux (histogramme, variogramme), des caractéristiques complexes du phénomène.

12.3.4.1 Principe général

On définit une fonction objectif O à minimiser, qui mesure l'écart entre la réalisation simulée et les propriétés visées. Exemple classique :

$$O = \sum_h [\gamma_{\text{sim}}(h) - \gamma_{\text{théo}}(h)]^2 + \alpha \sum_z [f_{\text{sim}}(z) - f_{\text{cible}}(z)]^2 \quad (22)$$

où γ est le variogramme, f l'histogramme, et α un poids. La fonction objectif peut aussi inclure des courbes tonnage-teneur (contexte minier), des relations déterministes entre variables, des contraintes géologiques (structures, contacts) ou des statistiques d'ordre supérieur (connectivité, proportions, asymétries spatiales).

12.3.4.2 Algorithme

1. **Initialisation.** Tirer aléatoirement une valeur pour chaque point à simuler en respectant l'histogramme désiré, placer les valeurs conditionnantes (points observés) dans le champ, calculer le variogramme expérimental et évaluer O_0 .
2. **Itération** ($i = 1, 2, \dots$).
 - a) Tirer au hasard un point du champ : si c'est un point conditionnant, ne rien changer ; sinon, tirer une nouvelle valeur z' selon la distribution cible.
 - b) Calculer la nouvelle fonction objectif O_{i+1} .
 - c) Décider d'accepter ou non selon la règle de Metropolis :

$$p_{\text{accept}} = \exp \left(-\frac{O_{i+1} - O_i}{T} \right), \quad (23)$$

où T est la « température » : si $O_{i+1} < O_i$, on accepte toujours (amélioration) ; sinon, on accepte avec probabilité p_{accept} .

3. **Refroidissement.** La température T diminue lentement selon un schéma défini (par exemple $T_{i+1} = \alpha T_i$ avec $\alpha \approx 0,95$) : en début de parcours, on explore largement l'espace des solutions (pour échapper aux minima locaux) ; en fin, on converge vers un optimum global.
4. **Critère d'arrêt.** On arrête lorsque $O < O_{\text{seuil}}$ ou après un nombre maximal d'itérations.

12.3.4.3 Remarques

Initialisation. Mieux vaut amorcer le recuit avec une réalisation SGS ou matricielle plutôt qu'avec un champ purement aléatoire : la convergence est plus rapide.

Flexibilité. La fonction objectif s'enrichit très facilement de contraintes spécifiques (géologiques, géométriques, statistiques).

Coût computationnel. Le recuit est généralement plus coûteux que les méthodes matricielles ou SGS, car il explore beaucoup de configurations avant d'en accepter une. On le réserve aux cas où les méthodes classiques ne satisfont pas toutes les contraintes à la fois, comme méthode de dernier recours.

La SGS construit la réalisation conditionnelle progressivement, point par point, chaque valeur simulée devenant donnée conditionnante pour les suivantes. Le post-conditionnement par krigeage (section suivante) procède autrement : il rend conditionnel en une seule fois un champ déjà entièrement simulé.

Atelier interactif 12.2 — Animation SGS

Cet atelier interactif n'est disponible que dans la version web du chapitre.

12.4 Post-conditionnement par krigeage simple (ou ordinaire)

Certaines méthodes de simulation ne produisent pas directement des réalisations conditionnelles. Pour combler ce manque, on a recourt au post-conditionnement par krigeage.

L'idée consiste à transformer une réalisation non conditionnelle en lui ajoutant un terme correctif, obtenu par krigeage de l'écart entre les données observées et les valeurs simulées aux points d'échantillonnage. Le champ ajusté respecte alors exactement les données mesurées, tout en conservant la structure spatiale et statistique de la réalisation initiale.

12.4.1 Principe du post-conditionnement par krigeage

On suppose que $Z(\mathbf{x})$ est gaussienne de moyenne nulle. La démarche se résume à trois étapes.

1. Simulation non conditionnelle.

On génère une réalisation non conditionnelle $Z_{nc}(\mathbf{x})$ sur l'ensemble du domaine, couvrant les points de prédiction où l'on veut simuler la variable ainsi que les points d'échantillonnage $\mathbf{x}_i$ où des observations existent. On note $Z_{nc}(\mathbf{x}_i)$ les valeurs simulées aux points d'observation ; elles ne coïncident pas avec les données réelles $Z_{obs}(\mathbf{x}_i)$.

2. Krigeage des données observées et simulées.

On fait ensuite un krigeage simple (ou ordinaire) sur tout le domaine, avec deux jeux de données : $Z_{kr,obs}(\mathbf{x})$, estimation à partir des données observées $Z_{obs}(\mathbf{x}_i)$; et $Z_{kr,nc}(\mathbf{x})$, estimation à partir des valeurs simulées non conditionnelles aux points d'observation $Z_{nc}(\mathbf{x}_i)$. Ces deux champs krigés mesurent l'écart entre ce qui devrait être observé (données réelles) et ce qui est effectivement simulé.

3. Correction additive.

La simulation conditionnelle s'obtient en corrigeant la réalisation non conditionnelle :

$$Z_{cond}(\mathbf{x}) = Z_{nc}(\mathbf{x}) + [Z_{kr,obs}(\mathbf{x}) - Z_{kr,nc}(\mathbf{x})] \quad (24)$$

Le terme correctif $[Z_{kr,obs}(\mathbf{x}) - Z_{kr,nc}(\mathbf{x})]$ est l'erreur de conditionnement à ajouter pour que la simulation respecte les données. Le résultat $Z_{cond}(\mathbf{x})$ reproduit alors les valeurs observées tout en préservant la structure de corrélation de la simulation initiale.

La Figure 5 illustre le principe. Pour rendre conditionnelle une simulation qui ne l'était pas, il suffit de lui ajouter l'erreur de krigeage entre les observations et la simulation ; la réalisation est alors contrainte de respecter exactement les valeurs échantillonnées.




FIGURE 5 : Principe du post-conditionnement par krigeage.

12.4.2 Propriétés mathématiques

1. Exactitude aux points d'observation.

Si un point $\mathbf{x}_0$ coïncide avec un point d'observation $\mathbf{x}_i$, le krigeage interpole exactement les données, donc

$$Z_{\text{kr,obs}}(\mathbf{x}_i) = Z_{\text{obs}}(\mathbf{x}_i) \quad \text{et} \quad Z_{\text{kr,nc}}(\mathbf{x}_i) = Z_{\text{nc}}(\mathbf{x}_i), \quad (25)$$

et par conséquent

$$Z_{\text{cond}}(\mathbf{x}_i) = Z_{\text{nc}}(\mathbf{x}_i) + [Z_{\text{obs}}(\mathbf{x}_i) - Z_{\text{nc}}(\mathbf{x}_i)] = Z_{\text{obs}}(\mathbf{x}_i). \quad (26)$$

La simulation post-conditionnée reproduit donc parfaitement les valeurs observées. À l'inverse, loin de toute donnée, l'influence du krigeage s'estompe et les deux champs krigés tendent vers la moyenne (nulle ici), de sorte que

$$Z_{\text{kr,obs}}(\mathbf{x}) \approx Z_{\text{kr,nc}}(\mathbf{x}) \approx 0 \quad \Rightarrow \quad Z_{\text{cond}}(\mathbf{x}) \approx Z_{\text{nc}}(\mathbf{x}). \quad (27)$$

Dans les zones non informées, la simulation conditionnée retrouve alors la simulation non conditionnelle initiale.

Variance de l'erreur de conditionnement. On peut montrer que la variance de l'erreur entre la simulation conditionnelle et la vraie valeur (inconnue) vérifie

$$\text{Var} [Z_{\text{cond}}(\mathbf{x}) - Z(\mathbf{x})] = 2\sigma_{\text{SK}}^2(\mathbf{x}), \quad (28)$$

où $\sigma_{\text{SK}}^2(\mathbf{x})$ est la variance de krigeage simple au point $\mathbf{x}$. Autrement dit, une seule réalisation conditionnelle post-conditionnée a une variance d'erreur deux fois plus grande que l'estimateur de krigeage simple. Il ne faut donc jamais utiliser une seule simulation post-conditionnée comme estimateur ponctuel : on sous-estimerait l'incertitude.

2. Convergence de la moyenne des simulations conditionnelles.

Pour S simulations conditionnelles indépendantes $\{Z_{\text{cond}}^{(s)}(\mathbf{x})\}_{s=1}^S$, la moyenne

$$\bar{Z}_{\text{cond}}(\mathbf{x}) = \frac{1}{S} \sum_{s=1}^S Z_{\text{cond}}^{(s)}(\mathbf{x}) \quad (29)$$

converge, quand $S \rightarrow \infty$, vers l'estimateur de krigeage simple :

$$\bar{Z}_{\text{cond}}(\mathbf{x}) \xrightarrow{S \rightarrow \infty} Z_{\text{SK}}(\mathbf{x}). \quad (30)$$

De plus, la variance d'estimation de cette moyenne converge vers la variance de krigeage simple,

$$\text{Var} [\bar{Z}_{\text{cond}}(\mathbf{x})] \xrightarrow{S \rightarrow \infty} \sigma_{\text{SK}}^2(\mathbf{x}), \quad (31)$$

et la dispersion des réalisations autour de cette moyenne (variance inter-réalisations) vaut elle aussi $\sigma_{\text{SK}}^2(\mathbf{x})$. Après moyennage d'un nombre suffisant de réalisations, le post-conditionnement reconstitue donc à la fois l'estimation optimale (krigeage simple) et l'incertitude associée (variance de krigeage), tout en fournissant des réalisations qui respectent la variabilité spatiale réelle du phénomène.

12.5 Propriétés des simulations

Les propriétés statistiques d'une réalisation dépendent de son caractère conditionnel ou non. La Figure 6 illustre ces différences de comportement et le rapport aux observations.

Non-conditionnelle	Conditionnelle
$E[Z_s] = m$	$E[Z_{sc}] = Z^*$
$\text{Var}(Z_s) = \sigma^2$	$\text{Var}(Z_{sc}) = \sigma_{KS}^2$
$\text{Var}(Z - Z_s) = 2\sigma^2$	$\text{Var}(Z - Z_{sc}) = 2\sigma_{KS}^2$

FIGURE 6 : Propriétés des simulations conditionnelles et non conditionnelles.

Une simulation non conditionnelle $Z_s(\mathbf{x})$ a une espérance constante, égale à la moyenne globale du modèle m : aucune information spatiale ne la contraint. Une simulation conditionnelle $Z_{sc}(\mathbf{x})$, elle, voit son espérance converger vers le krigeage simple $Z_{\text{SK}}^*(\mathbf{x})$. Son espérance varie donc dans l'espace selon la proximité et la configuration des observations, ce qui capte la structure d'information locale. Aux points d'observation, Z_{SK}^* reproduit exactement les mesures ; loin de toute donnée, elle revient vers la moyenne m et rejoint le comportement non conditionnel.

La variance spatiale est l'autre contraste. Une simulation non conditionnelle conserve toute la variance *a priori* du phénomène (σ^2), sans contraindre la variabilité du champ. Le conditionnement, au contraire, la réduit à σ_{SK}^2 , la variance de krigeage simple, qui mesure l'incertitude résiduelle une fois les données prises en compte. La réduction est maximale aux points d'observation (où $\sigma_{SK}^2 = 0$) et s'atténue avec la distance, jusqu'à retrouver la variance globale σ^2 dans les zones non informées. Le rapport σ_{SK}^2/σ^2 mesure la part d'incertitude non résolue par les observations : plus il est faible, plus le conditionnement est informatif.

L'erreur de prédiction, l'écart entre la vraie valeur inconnue $Z(\mathbf{x})$ et la valeur simulée, a elle aussi une structure intéressante. Pour une simulation non conditionnelle, sa variance vaut $2\sigma^2$, le double de la variance du champ : Z et Z_s sont deux réalisations indépendantes du même processus, donc la variance de leur différence est la somme des variances, $\sigma^2 + \sigma^2 = 2\sigma^2$. Dans le cas conditionnel, même logique, mais avec la variance réduite : $\text{Var}(Z - Z_{sc}) = 2\sigma_{SK}^2$. Une seule réalisation conditionnelle ne doit donc jamais servir d'estimateur ponctuel : son erreur quadratique moyenne est deux fois celle du krigeage simple. En revanche, la moyenne d'un grand nombre de simulations conditionnelles converge vers le krigeage, tout en mesurant l'incertitude globale par la dispersion des réalisations (Figure 7).




FIGURE 7 : Effet du nombre de réalisations : la moyenne (E-type) converge vers l'estimé de krigeage simple et la variance des réalisations vers la variance de krigeage.

Le conditionnement modifie donc les propriétés statistiques des simulations en y injectant l'information issue des observations. Là où une simulation non conditionnelle ne reflète que le modèle *a priori* (moyenne m , variance σ^2), une simulation conditionnelle intègre la structure spatiale des données : espérance conditionnelle (le krigeage Z_{SK}^*) et variance conditionnelle ($\sigma_{SK}^2 \leq \sigma^2$). Cette réduction ne permet toutefois pas de réaliser des simulations conditionnelles des estimateurs plus précises qu'une réalisation isolée : leur variance d'erreur reste le double de celle du krigeage. Leur force réside ailleurs : générer de multiples scénarios équiprobables qui, ensemble, chiffrent l'incertitude tout en conservant la variabilité spatiale du phénomène, ce que le krigeage, par son lissage, ne peut pas garantir.

Atelier interactif 12.3 — Non conditionnel ou conditionnel

Cet atelier interactif n'est disponible que dans la version web du chapitre.

La moyenne et la variance ne sont que les deux premiers moments. Le vrai intérêt des simulations se révèle dès qu'on cherche une quantité non linéaire de la teneur, un volume au-delà d'un seuil, un tonnage récupérable, que le krigeage, par son lissage, estime mal (Figure 8). Les deux ateliers suivants l'illustrent, l'un sur un site contaminé, puis l'autre sur un gisement minier.




FIGURE 8 : Quantiles P10/P50/P90 et probabilité de dépassement : les simulations révèlent un halo à risque que le krigeage lissé, seuillé, écrase.

Atelier interactif 12.4 — Site contaminé : krigeage ou simulations

Cet atelier interactif n'est disponible que dans la version web du chapitre.

Atelier interactif 12.5 — Ressources minières : krigeage ou simulations

Cet atelier interactif n'est disponible que dans la version web du chapitre.

12.6 Méthodes de simulation avancées

La décomposition de Cholesky des sections précédentes est simple et exacte, mais son coût en $\mathcal{O}(n^3)$ la limite à quelques milliers de points. Dès qu'on veut simuler sur de grandes grilles, il faut des générateurs plus efficaces. Cette section présente quatre méthodes classiques de simulation non conditionnelle d'un champ gaussien stationnaire de covariance $C(\mathbf{h})$: les bandes tournantes, leur variante spectrale, la

FFT-MA et la décomposition de Karhunen–Loève. Chacune a un atout propre — passage à l'échelle pour les trois premières, paramétrisation réduite pour la dernière.

Toutes produisent une réalisation *non conditionnelle*. Pour honorer des données, on les combine au post-conditionnement par krigeage (section précédente). Et comme la décomposition de Cholesky, elles supposent la variable gaussienne : une variable asymétrique se traite par anamorphose (voir la section sur la simulation non conditionnelle).

Plusieurs de ces méthodes s'expriment dans le domaine spectral. On y utilise la **densité spectrale** $f(\omega)$ de la covariance, définie par le théorème de Bochner :

$$C(\mathbf{h}) = \int_{\mathbb{R}^d} e^{i \langle \omega, \mathbf{h} \rangle} f(\omega) d\omega, \quad \int_{\mathbb{R}^d} f(\omega) d\omega = C(\mathbf{0}) = \sigma^2.$$

Une covariance admissible a une densité spectrale positive. Normalisée par σ^2 , elle devient une densité de probabilité, ce dont les méthodes spectrales tirent parti.

12.6.1 Bandes tournantes

La méthode des bandes tournantes (Matheron) ramène une simulation en dimension d à une somme de simulations unidimensionnelles le long de droites (Figure 9). On tire L directions unitaires $\mathbf{u}_1, \dots, \mathbf{u}_L$ réparties sur la sphère. Sur chaque droite ℓ , on simule un processus 1D indépendant $X_\ell(t)$ de covariance C_1 , puis on projette et on somme :

$$Z(\mathbf{x}) = \frac{1}{\sqrt{L}} \sum_{\ell=1}^L X_\ell(\langle \mathbf{x}, \mathbf{u}_\ell \rangle),$$

où $\langle \mathbf{x}, \mathbf{u}_\ell \rangle$ est l'abscisse de la projection de $\mathbf{x}$ sur la droite ℓ . Chaque droite n'apporte qu'une structure « en bandes » perpendiculaires à sa direction ; c'est leur superposition sur des directions bien réparties qui reconstruit l'isotropie (ou l'anisotropie voulue), et le théorème central limite rend le champ gaussien lorsque $L \rightarrow \infty$.

Le point clé est le lien entre la covariance 1D à simuler et la covariance cible. En trois dimensions, pour des directions uniformes sur la sphère et une covariance isotrope $C_3(r)$, ce lien est particulièrement simple :

$$C_3(r) = \frac{1}{r} \int_0^r C_1(s) ds \quad \Longleftrightarrow \quad C_1(r) = \frac{d}{dr} [r C_3(r)].$$

On déduit donc la covariance des processus de droite de la covariance 3D visée ; elle admet une forme explicite pour les modèles usuels (sphérique, exponentiel, etc.). En deux dimensions, la relation fait intervenir une transformée intégrale moins commode : en pratique, on simule alors en 3D et on prélève une section plane, ou on recourt à la variante spectrale ci-dessous.

Les processus 1D se simulent par n'importe quelle méthode unidimensionnelle (discrétisation de la droite, ou approche spectrale). Le coût total croît essentiellement comme $\mathcal{O}(Ln)$, linéaire en nombre de points : c'est ce qui rend la méthode efficace sur de grands domaines. Sa faiblesse est visuelle : trop peu de droites laissent apparaître des artefacts de bandes (des stries dans le champ simulé). On emploie donc un grand nombre de directions, réparties de façon régulière (suites quasi aléatoires) plutôt que purement aléatoires, pour lisser ces artefacts.




FIGURE 9 : Principe des bandes tournantes : projection sur des droites orientées, simulation d'un processus 1D par bande, puis recombinaison.

12.6.2 Bandes tournantes spectrales

La variante spectrale simule chaque processus de droite non pas en discrétisant la droite, mais par une représentation en cosinus. Un processus 1D stationnaire s'obtient en effet en tirant une fréquence dans sa densité spectrale et une phase aléatoire. En combinant la direction de bande $\mathbf{u}_\ell$ et la fréquence 1D, on aboutit directement à la méthode spectrale en dimension d :

$$Z(\mathbf{x}) = \sqrt{\frac{2}{L}} \sum_{\ell=1}^L \cos(\langle \omega_\ell, \mathbf{x} \rangle + \phi_\ell),$$

où le champ est pris centré réduit ($\sigma^2 = 1$), les vecteurs de fréquence $\omega_\ell = \omega_\ell \mathbf{u}_\ell$ sont tirés selon la densité spectrale normalisée $f(\omega)/\sigma^2$, et les phases $\phi_\ell \sim U[0, 2\pi]$ sont indépendantes.

La méthode reproduit la covariance de façon remarquablement directe. Pour un seul mode, l'espérance sur la phase donne

$$\mathbb{E}[2 \cos(\langle \omega, \mathbf{x} \rangle + \phi) \cos(\langle \omega, \mathbf{x} + \mathbf{h} \rangle + \phi)] = \cos(\langle \omega, \mathbf{h} \rangle),$$

et l'espérance sur la fréquence, comme f est symétrique, redonne exactement $\mathbb{E}[\cos(\langle \omega, \mathbf{h} \rangle)] = C(\mathbf{h})$. Un seul mode a donc déjà la bonne covariance ; la somme sur L modes réduit la variance de la covariance empirique et, par le théorème central limite, rend le champ gaussien.

Cette approche a deux avantages sur les bandes tournantes discrétisées. Elle est *continue* : on évalue $Z(\mathbf{x})$ en n'importe quel point, sans grille ni discrétisation des droites. Et elle reproduit la covariance sans biais, mode par mode. Elle suppose en revanche de savoir échantillonner la densité spectrale — connue en forme close pour les modèles courants (au modèle gaussien correspond une densité spectrale gaussienne, à l'exponentiel une densité de type Cauchy) — et reste sujette, comme toute méthode à L fini, à un léger bruit résiduel si L est trop petit.

12.6.3 FFT-MA

La FFT-MA (*Fast Fourier Transform — Moving Average*, Le Ravalec, Noetinger et Hu) simule sur une grille régulière en exploitant la transformée de Fourier rapide. Elle repose sur l'écriture d'un champ gaussien stationnaire comme une convolution (moyenne mobile) d'un bruit blanc ε par un noyau g :

$$Z = g * \varepsilon.$$

La covariance d'une convolution est l'autocorrélation du noyau ; dans le domaine spectral, cela impose $|\hat{g}(\omega)|^2 = \hat{C}(\omega) = f(\omega)$. Il suffit donc de prendre pour noyau la racine de la densité spectrale, $\hat{g} = \sqrt{\hat{C}}$. Comme une convolution devient un produit en Fourier, l'algorithme est immédiat :

1. évaluer la covariance sur la grille (périodisée) et en calculer la transformée de Fourier $\hat{C}$;
2. poser $\hat{g} = \sqrt{\hat{C}}$;
3. générer un bruit blanc ε sur la grille et le transformer, $\hat{\varepsilon}$;
4. multiplier terme à terme, $\hat{Z} = \sqrt{\hat{C}} \hat{\varepsilon}$;
5. transformer en sens inverse pour obtenir Z .

Le coût est celui de la FFT, $\mathcal{O}(N \log N)$ pour N nœuds : la méthode traite sans peine des grilles de plusieurs millions de cellules. Deux conditions l'encadrent. La grille doit être régulière. Et la transformée de la covariance périodisée doit rester positive ($\hat{C} \geq 0$) pour que sa racine ait un sens ; on l'assure en rembourrant le domaine (en l'agrandissant) de sorte que la covariance décroisse jusqu'à être négligeable dans la zone ajoutée, ce qui évite du même coup les artefacts de périodicité (le champ qui « se recolle » d'un bord à l'autre). La méthode est en cela une cousine de l'immersion circulante (*circulant embedding*).

Un atout distingue la FFT-MA : elle sépare le bruit blanc ε — la « graine » aléatoire — de la structure de covariance. Perturber légèrement le bruit perturbe continûment la réalisation, ce qui rend la méthode précieuse pour le calage d'historique et les problèmes inverses, où l'on cherche à déformer une réalisation pour l'ajuster à des observations.

12.6.4 Décomposition de Karhunen–Loève

La décomposition de Karhunen–Loève (KL) représente le champ comme une série de fonctions spatiales déterministes pondérées par des coefficients aléatoires décorrélés. Pour un champ centré de covariance $C(\mathbf{x}, \mathbf{y})$ sur un domaine $\mathcal{D}$:

$$Z(\mathbf{x}) = \sum_{k=1}^{\infty} \sqrt{\lambda_k} \xi_k \phi_k(\mathbf{x}),$$

où les couples (λ_k, ϕ_k) sont les valeurs et fonctions propres de l'opérateur de covariance, solutions de l'équation intégrale de Fredholm

$$\int_{\mathcal{D}} C(\mathbf{x}, \mathbf{y}) \phi_k(\mathbf{y}) d\mathbf{y} = \lambda_k \phi_k(\mathbf{x}),$$

les fonctions propres ϕ_k étant orthonormées, les valeurs propres ordonnées $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$, et les coefficients ξ_k décorrélés, de moyenne nulle et de variance unité. Pour un champ gaussien, les ξ_k sont indépendants et suivent $\mathcal{N}(0, 1)$.

La décomposition est optimale au sens suivant : parmi toutes les représentations linéaires tronquées à M termes, celle de KL minimise l'erreur quadratique moyenne intégrée $\mathbb{E} \int_{\mathcal{D}} (Z - Z_M)^2 \, d\mathbf{x}$. C'est donc la représentation la plus parcimonieuse. On tronque en gardant les M plus grandes valeurs propres ; la fraction de variance restituée est $\sum_{k=1}^M \lambda_k / \sum_{k=1}^{\infty} \lambda_k$. La décroissance des valeurs propres commande le nombre de termes utiles : rapide pour un champ très continu (covariance gaussienne), lente pour un champ irrégulier.

Sur une grille, l'équation de Fredholm se ramène à la décomposition en valeurs propres de la matrice de covariance $\mathbf{K} = \Phi \Lambda \Phi^\top$, et la réalisation s'écrit $\mathbf{z} = \Phi \Lambda^{1/2} \mathbf{y}$ avec $\mathbf{y}$ gaussien centré réduit : c'est la décomposition spectrale évoquée comme extension de la méthode matricielle. Le calcul complet des vecteurs propres coûte $\mathcal{O}(N^3)$, comme Cholesky, mais on peut ne calculer que les M premiers modes. Le véritable intérêt de KL n'est donc pas la vitesse, mais la *paramétrisation réduite* : le champ est décrit par $M \ll N$ coefficients, ce qui sert en quantification d'incertitude, en éléments finis stochastiques (chaos polynomial) et en problèmes inverses. Son conditionnement aux données est en revanche moins direct que le post-conditionnement.

12.6.5 Comparaison

Méthode	Support	Coût	Atout principal	Limite
Bandes tournantes	points ou grille	$\mathcal{O}(L n)$	rapide, tout support	artefacts de bandes si L faible ; relation 1D–3D simple surtout en 3D
Bandes tournantes spectrales	points ou grille	$\mathcal{O}(L n)$	continu, évaluable partout	requiert la densité spectrale
FFT-MA	grille régulière	$\mathcal{O}(N \log N)$	très rapide ; découple bruit et structure	grille et rembourrage ; $\hat{C} \geq 0$
Karhunen–Loève	points ou grille	$\mathcal{O}(N^3)$, ou M modes	paramétrisation réduite (M coefficients)	coût de la décomposition ; conditionnement indirect

Le choix dépend du contexte : FFT-MA pour de très grandes grilles régulières, bandes tournantes (spectrales) pour un support quelconque ou une évaluation en des points isolés, Karhunen–Loève quand une représentation réduite du champ est recherchée. Dans tous les cas, la réalisation produite est non conditionnelle et se rend conditionnelle par post-conditionnement.