

Simulations géostatistiques de variable continue

Ce chapitre présente les principes fondamentaux et les applications des simulations géostatistiques à la modélisation de variables spatiales continues. L'intérêt majeur de la simulation réside dans sa capacité à quantifier l'incertitude et à produire des images spatiales qui reflètent la variabilité des données de terrain. Après avoir distingué l'estimation de la simulation, nous détaillons les processus conditionnels et non conditionnels, ainsi que les algorithmes de référence (Cholesky, SGS). Ce chapitre présente les critères pour choisir la méthode la plus adaptée à un contexte donné, tout en soulignant les limites intrinsèques de chaque approche pour la simulation d'une variable régionalisée.

Table des matieres

1	Notations et hypothèses	3
1.1	Problématique du câble sous-marin (Alfaro, 1979)	3
1.2	Estimation versus Simulation	5
2	Simulation non conditionnelle d'une variable continue	6
2.1	Méthode de simulation matricielle (décomposition de Cholesky)	7
	Principe	7
	Validation de la méthode	8
	Limitations	8
	Extensions	8
2.2	Cas des variables non gaussiennes : l'anamorphose	8
2.3	Passage à la simulation conditionnelle	9
	Atelier interactif 12.1 — Reproduction du variogramme	9
3	Simulation conditionnelle d'une variable continue	9
3.1	Méthode de simulation matricielle conditionnelle	9
	Principe	9
	Algorithme	10
	Efficacité computationnelle	11
	Limitations	11
3.2	Méthode de simulation séquentielle gaussienne (SGS)	11
	Principe général	11
	Algorithme	11
	Validation théorique	12
	Remarques importantes	13
3.3	Comparaison des deux méthodes	13

3.4 Méthode de recuit simulé	14
Principe général	14
Algorithme	14
Remarques	15
Atelier interactif 12.2 — Animation SGS	15
4 Post-conditionnement par krigeage	16
4.1 Principe du post-conditionnement par krigeage	16
4.2 Propriétés mathématiques	17
5 Propriétés des simulations	18
Atelier interactif 12.3 — Non conditionnel vs conditionnel	19
Atelier interactif 12.4 — Site contaminé : krigeage vs simulations	20
Atelier interactif 12.5 — Ressources minières : krigeage vs simulations	20
6 Exercices	20
6.1 Exercice 1 — Transformation gaussienne (données de Dallas, plomb)	20
6.2 Exercice 2 — Recuit simulé	21
6.3 Exercice 3 — Contraintes minières	22
6.4 Exercice 4 — Simulation séquentielle gaussienne	23
6.5 Exercice 5 — Propriétés des simulations (non conditionnelles vs conditionnelles)	24
6.6 Exercice 6 — Post-conditionnement par krigeage simple	24
6.7 Exercice 7 — Décomposition de Cholesky (méthode LU)	26
6.8 Exercice 8 — Étude de cas : arsenic autour d’une fonderie	27

! Objectifs d’apprentissage

- Identifier les types de problèmes pour lesquels les méthodes de simulation géostatistique sont appropriées ;
- Distinguer clairement les concepts d’estimation et de simulation, ainsi que leurs objectifs respectifs ;
- Expliquer les différences fondamentales entre les simulations non conditionnelles et conditionnelles ;
- Appliquer les méthodes de simulation de Cholesky et de simulation séquentielle gaussienne (SGS), et en discuter les avantages et les limites ;
- Utiliser et interpréter les résultats de simulations géostatistiques dans le cadre de l’estimation des ressources ;
- Comprendre et expliquer les principales propriétés statistiques et spatiales des simulations.

i Références

Ce chapitre s’appuie principalement sur les ouvrages suivants :

Lantuéjoul, C. (2002). *Geostatistical Simulation : Models and Algorithms*. Springer.

Chilès, J., & Delfiner, P. (2012). *Geostatistics : Modeling Spatial Uncertainty*. John Wiley & Sons.

Alfaro, M. (1979). *Étude de la robustesse des simulations de fonctions aléatoires*. Thèse, École des Mines de Paris.

1 Notations et hypothèses

Les variables régionalisées sont modélisées comme des champs stochastiques (ou fonctions aléatoires) définis sur un domaine spatial $\mathcal{D} \subset \mathbb{R}^n$. Un champ stochastique $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$ est une famille de variables aléatoires indexées par la position spatiale $\mathbf{x}$, destinée à représenter l'incertitude et la variabilité spatiale d'un phénomène naturel.

Le krigeage et la simulation partagent la même base théorique du champ stochastique $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$, mais diffèrent par leur finalité : alors que le krigeage cherche l'estimateur local optimal en minimisant la variance d'erreur, la simulation vise à reproduire les propriétés statistiques globales du modèle. En pratique, le krigeage fournit l'espérance conditionnelle, ce qui entraîne un lissage spatial des valeurs et une sous-estimation de la variabilité réelle. À l'inverse, la simulation génère des réalisations qui respectent intégralement la structure spatiale imposée par le variogramme, permettant ainsi de passer d'une vision « moyenne » du phénomène à une représentation fidèle de son hétérogénéité et de son incertitude.

1.1 Problématique du câble sous-marin (Alfaro, 1979)

Cet exemple, fréquemment utilisé dans la littérature pour introduire les méthodes de simulation géostatistique, est l'un des plus classiques. L'étude proposée par Alfaro (1979) illustre la problématique de l'estimation de la longueur d'un câble sous-marin à partir de données bathymétriques discrètes ; les valeurs chiffrées présentées ci-dessous sont celles qu'en tirent Chilès et Delfiner (2012).

Considérons un domaine spatial unidimensionnel le long duquel la profondeur du fond marin est mesurée tous les 100 m. Une approche déterministe naturelle consiste à estimer la topographie du fond marin par krigeage à l'ensemble des points du profil, puis à calculer la longueur de la courbe ainsi obtenue. Appliquée à la section reprise par Chilès et Delfiner (2012), cette méthode conduit à une longueur estimée de $L = 945$ m.

Cependant, cette estimation est affectée par l'effet de lissage inhérent au krigeage, qui tend à réduire la variabilité spatiale de la variable régionalisée — ici le profil bathymétrique — et à atténuer les irrégularités de petite échelle. On observe aisément l'effet de lissage du krigeage dans l'estimé du profil.

Un levé bathymétrique beaucoup plus dense, avec un échantillonnage tous les 10 m, permet de mesurer une longueur réelle de $L = 1182$ m (Chilès et Delfiner, 2012), mettant en évidence une sous-estimation marquée liée à l'approche déterministe. Cette divergence illustre clairement que l'estimation de fonctions de transfert non linéaires, telles que la longueur d'une courbe, ne peut être correctement réalisée à partir d'un champ lissé, même lorsque celui-ci constitue un estimateur optimal au sens des moindres carrés.

La simulation géostatistique constitue une alternative pertinente pour pallier cette limitation, sans recourir à des campagnes de mesure supplémentaires coûteuses. En modélisant la profondeur $Z(\mathbf{x})$ comme une fonction aléatoire caractérisée par un variogramme $\gamma(h)$ spécifié, il est possible de générer des réalisations conditionnelles respectant la variabilité du processus. Contrairement au profil krigé, les réalisations simulées préservent la dispersion et la variabilité spatiales du champ stochastique, ce qui permet d'estimer une espérance de longueur à la fois mathématiquement cohérente et physiquement compatible avec les observations à petite échelle.




FIGURE 1 : Problématique du câble sous-marin (Alfaro, 1979). (a) Données bathymétriques et profil réel, (b) profil estimé par krigeage, (c) une réalisation simulée conditionnelle, (d) ensemble de simulations conditionnelles illustrant l'incertitude spatiale.

1.2 Estimation versus Simulation

Reprenons cette opposition de manière plus systématique. Le krigeage et la simulation géostatistique partagent le même cadre théorique — le modèle de champ stochastique $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$ — mais diffèrent par leurs objectifs et leurs propriétés :

Estimation par krigeage : L'estimateur de krigeage $Z^*(\mathbf{x}_0)$ correspond au **BLUP** (*Best Linear Unbiased Predictor*) de la variable régionalisée en $\mathbf{x}_0$. Il s'agit de la meilleure prédiction linéaire sans biais, au sens de la minimisation de la variance de l'erreur de prédiction, et correspond à l'**espérance conditionnelle** de $Z(\mathbf{x}_0)$ en fonction des données observées :

$$Z^*(\mathbf{x}_0) = \mathbb{E}[Z(\mathbf{x}_0) \mid Z(\mathbf{x}_1), \dots, Z(\mathbf{x}_n)] \quad (1)$$

Cette approche produit un **lissage spatial** : les valeurs extrêmes sont atténuées, la variabilité locale est sous-estimée ($\text{Var}[Z^*] < \text{Var}[Z]$), et la structure de corrélation est partiellement perdue. Le krigeage fournit une représentation « moyenne » optimale pour l'estimation ponctuelle, mais inadaptée aux calculs de fonctionnelles non linéaires.

Simulation géostatistique : Une réalisation simulée $Z^{(s)}(\mathbf{x})$ est un tirage de la distribution conditionnelle qui respecte les propriétés statistiques du modèle :

$$Z^{(s)}(\mathbf{x}) \sim p(Z(\mathbf{x}) \mid Z(\mathbf{x}_1), \dots, Z(\mathbf{x}_n)) \quad (2)$$

Chaque simulation :

- reproduit la structure de corrélation spatiale imposée par le variogramme $\gamma(h)$;
- reproduit la loi marginale (l'histogramme) du modèle ;
- préserve la variance du champ ($\text{Var}[Z^{(s)}] = \text{Var}[Z]$) ;
- honore exactement les valeurs observées aux points d'échantillonnage.

C'est cette double reproduction — structure spatiale et histogramme — qui distingue la simulation du krigeage, lequel ne restitue ni l'une ni l'autre.

Les réalisations ainsi obtenues constituent des **scénarios équiprobables** qui restituent l'hétérogénéité spatiale du phénomène étudié et permettent d'explorer de manière réaliste l'incertitude associée au modèle.

Relation entre krigeage et simulation : Pour un ensemble de S simulations conditionnelles indépendantes, la moyenne converge vers l'estimateur de krigeage simple Z_{SK}^* :

$$\lim_{S \rightarrow \infty} \frac{1}{S} \sum_{s=1}^S Z^{(s)}(\mathbf{x}) = Z_{SK}^*(\mathbf{x}) \quad (3)$$

Cette relation montre que le krigeage simple peut être vu comme la « moyenne » de toutes les réalisations possibles, expliquant ainsi son caractère lissé. Elle est exacte pour le krigeage simple (moyenne connue) et seulement approchée pour le krigeage ordinaire.

Propriétés comparatives :

Propriété	Krigeage $Z^*(\mathbf{x})$	Simulation $Z^{(s)}(\mathbf{x})$
Objectif	Prédiction optimale (BLUP)	Reproduction de la variabilité

Propriété	Krigeage $Z^*(\mathbf{x})$	Simulation $Z^{(s)}(\mathbf{x})$
Variance spatiale	$\text{Var}[Z^*] < \text{Var}[Z]$ (sous-estimation)	$\text{Var}[Z^{(s)}] = \text{Var}[Z]$ (préservée)
Vario-gramme	Partiellement reproduit (lissage)	Intégralement reproduit
Conditionnement	Exact aux observations	Exact aux observations
Valeurs extrêmes	Atténuées	Préservées
Erreur ponctuelle	Minimale (variance de krigeage)	Plus élevée qu'une estimation
Fonctionnelles non linéaires	Biaisées (effet de lissage)	Non biaisées (sur moyenne des réalisations)
Quantification d'incertitude	Variance de krigeage (locale)	Dispersion des réalisations (globale)
Nombre de résultats	Une seule estimation	Multiples scénarios équiprobables

Cas d'usage :

- **Utiliser le krigeage** lorsque l'objectif est d'obtenir la meilleure **estimation ponctuelle** en chaque point, par exemple pour cartographier une moyenne spatiale ou interpoler des valeurs manquantes.
- **Utiliser la simulation** lorsque l'objectif est de :
 - Quantifier l'**incertitude spatiale globale**
 - Évaluer des **fonctionnelles non linéaires** (volumes, longueurs, seuils de dépassement)
 - Analyser des **scénarios extrêmes** (pire cas, meilleur cas)
 - Modéliser la **connectivité** ou la **continuité** spatiale
 - Effectuer des **analyses de risque** ou de **propagation d'incertitude**

Illustration : Dans le cas du câble sous-marin (Figure 1), le krigeage produit un profil lissé qui sous-estime systématiquement la longueur réelle ($L_{\text{krigeage}} = 945$ m vs $L_{\text{réel}} = 1182$ m), tandis que la moyenne sur plusieurs simulations conditionnelles fournit une estimation non biaisée de cette fonctionnelle non linéaire :

$$\mathbb{E}[L] \approx \frac{1}{S} \sum_{s=1}^S L(Z^{(s)}(\mathbf{x})) \quad (4)$$

où $L(\cdot)$ désigne la fonctionnelle longueur appliquée à chaque réalisation simulée.

2 Simulation non conditionnelle d'une variable continue

La simulation non conditionnelle vise à générer des réalisations d'un champ aléatoire $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$ sans imposer de contrainte aux points d'observation. Ces réalisations doivent respecter les propriétés

statistiques du modèle spatial (variogramme ou covariance) et la distribution marginale des valeurs, mais ne sont pas contraintes de passer exactement par des données mesurées.

Plusieurs méthodes permettent de réaliser des simulations non conditionnelles, parmi lesquelles :

- Méthodes matricielles (décomposition de Cholesky, LU)
- Moyennes mobiles
- Bandes tournantes
- Méthodes autorégressives
- Méthodes fréquentielles (FFT-MA)

Les **bandes tournantes** ramènent une simulation à n dimensions à un ensemble de simulations 1D le long de droites, recombinaées ensuite par projection ; elles sont efficaces sur de grands domaines. Les **méthodes fréquentielles**, dont la FFT-MA (*Fast Fourier Transform — Moving Average*), simulent dans le domaine spectral et tirent parti de la transformée de Fourier rapide sur grille régulière. Pour leur description détaillée, on renvoie à Lantuéjoul (2002) et Chilès et Delfiner (2012). Nous présentons ici la **méthode matricielle par décomposition de Cholesky**, qui constitue une approche de référence pour les champs de taille modérée.

2.1 Méthode de simulation matricielle (décomposition de Cholesky)

Cette méthode est simple à programmer et efficace pour simuler de petits champs. Elle repose sur une décomposition algébrique de la matrice de covariance.

Principe

Soit n points à simuler, pour lesquels on souhaite générer une réalisation d'un champ aléatoire de covariance $C(h)$. On procède en trois étapes :

1. **Construction de la matrice de covariance** : On évalue la covariance entre chaque paire de points à simuler pour construire la matrice $\mathbf{K}$ de taille $n \times n$:

$$K_{ij} = C(\mathbf{x}_i - \mathbf{x}_j), \quad i, j = 1, \dots, n \quad (5)$$

Cette matrice est symétrique et définie positive.

2. **Décomposition de Cholesky** : On décompose la matrice $\mathbf{K}$ sous la forme :

$$\mathbf{K} = \mathbf{L}\mathbf{L}^\top \quad (6)$$

où $\mathbf{L}$ est une matrice triangulaire inférieure. Cette décomposition est unique et existe toujours pour une matrice définie positive.

3. **Génération de la réalisation** : On tire n valeurs indépendantes $y_i \sim \mathcal{N}(0, 1)$ pour $i = 1, \dots, n$, formant le vecteur gaussien centré réduit $\mathbf{y}$. La réalisation simulée est alors :

$$\mathbf{z} = \mathbf{L}\mathbf{y} \quad (7)$$

Validation de la méthode

Cette réalisation possède bien la covariance souhaitée, puisque :

$$\begin{aligned}\text{Cov}[\mathbf{z}] &= \text{Cov}[\mathbf{L}\mathbf{y}] \\ &= \mathbf{L} \text{Cov}[\mathbf{y}] \mathbf{L}^\top \\ &= \mathbf{L} \mathbf{I} \mathbf{L}^\top \\ &= \mathbf{L} \mathbf{L}^\top \\ &= \mathbf{K}\end{aligned}\tag{8}$$

Ainsi, le vecteur simulé $\mathbf{z}$ est une réalisation non conditionnelle du champ gaussien de covariance $C(h)$.

Limitations

- **Taille du problème** : La méthode est limitée par la mémoire et le coût computationnel de la décomposition de Cholesky, qui croît en $\mathcal{O}(n^3)$. En pratique, elle est applicable pour $n \lesssim 10\,000$ points.
- **Matrice non singulière** : La matrice $\mathbf{K}$ doit être définie positive, ce qui exclut les configurations où des points sont exactement confondus.
- **Effet de pépité** : En présence d'un effet de pépité C_0 dans le modèle de covariance, il est préférable de l'ajouter après la simulation, sous forme d'un bruit blanc indépendant $\varepsilon \sim \mathcal{N}(0, C_0)$, pour ne pas perturber la structure spatiale simulée.

Extensions

D'autres décompositions sont possibles pour générer les simulations, notamment celles fondées sur les valeurs propres et les vecteurs propres de $\mathbf{K}$ (décomposition spectrale), mais la décomposition de Cholesky demeure l'approche la plus efficace dans les cas où elle est applicable.

2.2 Cas des variables non gaussiennes : l'anamorphose

La décomposition de Cholesky — comme la SGS présentée plus loin — suppose que la variable simulée est gaussienne. Or les teneurs minières sont rarement gaussiennes : elles sont le plus souvent asymétriques et proches d'une loi log-normale. On contourne cette difficulté par une **anamorphose gaussienne** : une fonction monotone φ telle que

$$Z(\mathbf{x}) = \varphi(Y(\mathbf{x})),\tag{9}$$

où $Y(\mathbf{x})$ est un champ gaussien. On simule alors Y — pour lequel toute la théorie de ce chapitre s'applique — puis on transforme chaque réalisation par $Z = \varphi(Y)$ pour retrouver la variable d'origine. Le cas log-normal correspond à $Z = \exp(Y)$. En pratique, φ est estimée à partir de l'histogramme des données, de sorte que les réalisations finales reproduisent la loi marginale observée. Cette transformation est celle qui sous-tend l'application au cas log-normal de l'atelier 12.4.

2.3 Passage à la simulation conditionnelle

Les réalisations non conditionnelles générées par cette méthode peuvent être transformées en simulations conditionnelles par **post-conditionnement par krigeage** (voir chapitre correspondant) ou en étendant directement la décomposition matricielle pour intégrer les observations (voir section suivante).

Atelier interactif 12.1 — Reproduction du variogramme

Cet atelier interactif est disponible uniquement dans la version web du chapitre.

3 Simulation conditionnelle d'une variable continue

La simulation conditionnelle vise à générer des réalisations d'un champ aléatoire $\{Z(\mathbf{x}) : \mathbf{x} \in \mathcal{D}\}$ qui **honorent exactement** les valeurs observées aux points d'échantillonnage, tout en respectant les propriétés statistiques du modèle spatial (variogramme, covariance) et la distribution marginale des valeurs.

Contrairement à l'estimation par krigeage qui fournit une représentation lissée du phénomène, la simulation conditionnelle préserve la variabilité spatiale réelle et permet de quantifier l'incertitude en générant de multiples scénarios équiprobables.

Il existe plusieurs méthodes de simulation conditionnelle pour les champs gaussiens :

- Méthodes matricielles (extension de la décomposition de Cholesky)
- Simulation séquentielle gaussienne (SGS)
- Post-conditionnement par krigeage
- Bandes tournantes conditionnelles
- Moyennes mobiles conditionnelles

Nous présentons ici deux approches fondamentales : la **méthode matricielle** et la **simulation séquentielle gaussienne (SGS)**.

3.1 Méthode de simulation matricielle conditionnelle

Principe

Le principe de la simulation conditionnelle matricielle est une extension directe de la méthode non conditionnelle. On distingue deux ensembles de points :

- Les N points conditionnants $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, pour lesquels les valeurs $\mathbf{z}_1 = [Z(\mathbf{x}_1), \dots, Z(\mathbf{x}_N)]^\top$ sont observées ;
- Les n points à simuler $\{\mathbf{x}_{N+1}, \dots, \mathbf{x}_{N+n}\}$, dont on souhaite générer une réalisation conforme aux observations.

Algorithme

1. **Construction de la matrice de covariance globale** : On construit la matrice $\mathbf{K}$ de taille $(N + n) \times (N + n)$ en plaçant d'abord les N points conditionnants, puis les n points à simuler :

$$\mathbf{K} = \begin{bmatrix} \mathbf{K}_{11} & \mathbf{K}_{12} \\ \mathbf{K}_{21} & \mathbf{K}_{22} \end{bmatrix} \quad (10)$$

où :

- $\mathbf{K}_{11}$ (taille $N \times N$) : covariances entre points conditionnants
 - $\mathbf{K}_{22}$ (taille $n \times n$) : covariances entre points à simuler
 - $\mathbf{K}_{12} = \mathbf{K}_{21}^\top$ (taille $N \times n$) : covariances croisées
2. **Décomposition de Cholesky par blocs** : On effectue la décomposition de Cholesky sur la matrice globale :

$$\mathbf{K} = \mathbf{L}\mathbf{L}^\top = \begin{bmatrix} \mathbf{L}_{11} & \mathbf{0} \\ \mathbf{L}_{21} & \mathbf{L}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{L}_{11}^\top & \mathbf{L}_{21}^\top \\ \mathbf{0} & \mathbf{L}_{22}^\top \end{bmatrix} \quad (11)$$

où :

- $\mathbf{L}_{11}$ correspond aux points conditionnants
 - $\mathbf{L}_{22}$ correspond aux points à simuler
 - $\mathbf{L}_{21}$ décrit la liaison entre ces deux groupes
3. **Détermination du vecteur conditionné** : Pour imposer un conditionnement exact, on détermine le vecteur $\mathbf{y}_1$ tel que :

$$\mathbf{z}_1 = \mathbf{L}_{11}\mathbf{y}_1 \quad (12)$$

d'où :

$$\mathbf{y}_1 = \mathbf{L}_{11}^{-1}\mathbf{z}_1 \quad (13)$$

4. **Génération de la composante aléatoire** : On tire un vecteur aléatoire $\mathbf{y}_2 \in \mathbb{R}^n$ composé de variables indépendantes $y_i \sim \mathcal{N}(0, 1)$.
5. **Construction de la simulation complète** : La simulation s'écrit :

$$\begin{bmatrix} \mathbf{z}_1 \\ \mathbf{z}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{L}_{11} & \mathbf{0} \\ \mathbf{L}_{21} & \mathbf{L}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{L}_{11}\mathbf{y}_1 \\ \mathbf{L}_{21}\mathbf{y}_1 + \mathbf{L}_{22}\mathbf{y}_2 \end{bmatrix} \quad (14)$$

Comme les valeurs observées $\mathbf{z}_1$ sont connues et que $\mathbf{y}_1$ est déterminé, seule la partie simulée varie d'une réalisation à l'autre :

$$\mathbf{z}_2 = \mathbf{L}_{21}\mathbf{y}_1 + \mathbf{L}_{22}\mathbf{y}_2 \quad (15)$$

Efficacité computationnelle

Le terme $\mathbf{L}_{21}\mathbf{y}_1$ est **constant** pour toutes les réalisations conditionnelles : il ne doit être calculé qu'une seule fois. Pour générer M réalisations conditionnelles :

1. On effectue **une seule fois** : la décomposition de Cholesky et le calcul de $\mathbf{L}_{21}\mathbf{y}_1$
2. Pour chaque réalisation $k = 1, \dots, M$: on tire un nouveau $\mathbf{y}_2^{(k)}$ et on calcule $\mathbf{z}_2^{(k)} = \mathbf{L}_{21}\mathbf{y}_1 + \mathbf{L}_{22}\mathbf{y}_2^{(k)}$

Cette approche est donc très efficace pour générer de multiples réalisations conditionnelles.

Limitations

- **Mémoire et temps de calcul** : La taille totale $(N + n)$ reste limitée à quelques milliers de points. Au-delà, la matrice $\mathbf{K}$ devient trop volumineuse.
- **Matrice non singulière** : La matrice $\mathbf{K}$ doit être définie positive. Les points à simuler ne doivent pas coïncider exactement avec les points observés.
- **Pas de voisinage mobile** : Tous les points conditionnants influencent tous les points simulés, ce qui peut être limitant pour des grands domaines avec de nombreuses observations.

3.2 Méthode de simulation séquentielle gaussienne (SGS)

La méthode SGS est une approche **point par point** qui construit séquentiellement une réalisation conditionnelle en utilisant les distributions conditionnelles dérivées du krigeage simple.

Principe général

L'algorithme visite successivement chaque point à simuler et tire une valeur selon la distribution gaussienne conditionnelle à l'information déjà disponible (observations initiales + valeurs déjà simulées). Cette valeur devient immédiatement une nouvelle donnée conditionnante pour les étapes suivantes.

Algorithme

Supposons que l'on dispose de N points conditionnants et que l'on souhaite simuler n points inconnus.

1. **Générer un chemin de simulation aléatoire** : On définit un ordre aléatoire de visite $\{\mathbf{x}_{\pi(1)}, \dots, \mathbf{x}_{\pi(n)}\}$ pour les n points à simuler. Cet ordre importe, car chaque valeur simulée influence les étapes suivantes.
2. **Parcourir les points séquentiellement** : Pour chaque point $\mathbf{x}_i$ selon l'ordre du chemin :
 - a) **Sélectionner les données conditionnantes** : On considère comme données :
 - Les N observations initiales
 - Les valeurs déjà simulées aux points précédents dans le chemin

- En pratique, on restreint à un **voisinage mobile** (par exemple, les k points les plus proches) pour limiter le coût computationnel
- b) **Effectuer un krigeage simple** au point $\mathbf{x}_i$ avec le modèle de covariance $C(h)$ (ou variogramme $\gamma(h)$). On obtient :

— La moyenne conditionnelle :

$$Z_i^* = \mathbb{E}[Z(\mathbf{x}_i) \mid \text{données connues}] \quad (16)$$

— La variance conditionnelle :

$$\sigma_{\text{SK}}^2(\mathbf{x}_i) = \text{Var}[Z(\mathbf{x}_i) \mid \text{données connues}] \quad (17)$$

- c) **Tirer une valeur aléatoire** selon la distribution gaussienne conditionnelle :

$$Z(\mathbf{x}_i) \sim \mathcal{N}(Z_i^*, \sigma_{\text{SK}}^2(\mathbf{x}_i)) \quad (18)$$

- d) **Ajouter la valeur simulée** à l'ensemble des données conditionnantes pour les étapes suivantes.

3. **Répéter** jusqu'à ce que tous les points du chemin aient été visités.

Validation théorique

La méthode SGS produit des réalisations qui respectent le variogramme cible. On peut le démontrer par induction :

Hypothèse : Supposons que n points simulés possèdent la bonne structure spatiale (covariance $\mathbf{K}_{nn}$).

Étape $n + 1$: Au point $n + 1$, la valeur krigée s'écrit :

$$Z_{n+1}^* = \lambda^\top \mathbf{Z}_{ns} \quad (19)$$

où $\lambda = \mathbf{K}_{nn}^{-1} \mathbf{K}_{n1}$ et $\mathbf{K}_{n1}$ est la covariance entre les n points déjà simulés et le point $n + 1$.

La valeur simulée est :

$$Z_{n+1} = Z_{n+1}^* + \varepsilon \quad (20)$$

où $\varepsilon \sim \mathcal{N}(0, \sigma_{\text{SK}}^2)$ est indépendant de $\mathbf{Z}_{ns}$.

Covariance avec les points précédents :

$$\begin{aligned} \text{Cov}[Z_{n+1}, \mathbf{Z}_{ns}] &= \text{Cov}[Z_{n+1}^* + \varepsilon, \mathbf{Z}_{ns}] \\ &= \text{Cov}[\lambda^\top \mathbf{Z}_{ns}, \mathbf{Z}_{ns}] + \text{Cov}[\varepsilon, \mathbf{Z}_{ns}] \\ &= \lambda^\top \mathbf{K}_{nn} + \mathbf{0} \\ &= \mathbf{K}_{n1} \end{aligned} \quad (21)$$

Variance au point $n + 1$:

$$\begin{aligned}
\text{Var}[Z_{n+1}] &= \text{Var}[Z_{n+1}^* + \varepsilon] \\
&= \text{Var}[\lambda^\top \mathbf{Z}_{ns}] + \text{Var}[\varepsilon] \\
&= \lambda^\top \mathbf{K}_{nn} \lambda + \sigma_{\text{SK}}^2 \\
&= C(0)
\end{aligned} \tag{22}$$

Donc les $n + 1$ points possèdent bien la structure de covariance souhaitée.

Cette démonstration suppose un **voisinage global** : à chaque étape, le krigeage utilise toutes les données et toutes les valeurs déjà simulées. La reproduction du variogramme est alors exacte. En pratique, on restreint le krigeage à un voisinage mobile (voir ci-dessous) ; la reproduction n'est plus qu'approchée — le palier reste correct, mais le raccord à distance intermédiaire est légèrement lissé.

Remarques importantes

Voisinage mobile : Pour éviter que les systèmes de krigeage ne deviennent trop lourds, on restreint le krigeage à une fenêtre locale. Les points éloignés ont peu d'influence (effet d'écran) et peuvent être ignorés sans perte significative.

Effet de pépité : - **Cas non conditionnel** : Il est préférable d'ajouter l'effet de pépité C_0 après la simulation, sous forme de bruit indépendant. - **Cas conditionnel** : On ne peut pas procéder ainsi car les observations incluent déjà l'effet de pépité et doivent être reproduites exactement.

Chemin de simulation : - Un parcours systématique peut créer des **artefacts directionnels**. - Il est recommandé d'utiliser un **ordre aléatoire**. - Pour améliorer la qualité : procéder en **plusieurs passes multi-échelles** (grossier $\rightarrow$ fin) pour capturer les structures à différentes échelles.

Généralité de la méthode : Bien que la normalité soit commode (le krigeage simple fournit exactement la distribution conditionnelle), la démonstration ne repose que sur les propriétés linéaires du krigeage. On peut donc simuler un bruit ε non gaussien (de moyenne nulle et variance σ_{SK}^2) : le variogramme sera respecté, mais l'histogramme tendra vers une forme plus gaussienne à cause du théorème central limite.

Extension multivariée : La méthode SGS se combine facilement avec la décomposition matricielle (LU) pour simuler simultanément plusieurs variables corrélées en multiples points.

3.3 Comparaison des deux méthodes

Critère	Méthode matricielle	SGS
Taille maximale	$N + n \lesssim 10\,000$	Quasi illimitée (avec voisinage mobile)
Coût pour 1 réalisation	$\mathcal{O}((N + n)^3)$ décomposition	$\mathcal{O}(n \times k^3)$ avec k voisins

Critère	Méthode matricielle	SGS
Coût pour M réalisations	Décomposition une fois, puis $\mathcal{O}(n)$ par réalisation	$\mathcal{O}(M \times n \times k^3)$
Voisinage mobile	Non	Oui
Effet de pépite	Traitement séparé recommandé	Inclus naturellement
Artefacts	Aucun	Possibles si chemin mal choisi
Flexibilité	Limitée	Haute (multi-échelle, multivariée)

Recommandation : - Utiliser la **méthode matricielle** pour générer **plusieurs réalisations** sur des champs de **taille modérée**. - Utiliser **SGS** pour des **grands domaines** avec **voisinage mobile**, ou lorsque des **contraintes complexes** doivent être intégrées.

3.4 Méthode de recuit simulé

La méthode du recuit simulé (*simulated annealing*) est une technique d'**optimisation** extrêmement flexible, utilisée lorsqu'il faut reproduire non seulement les moments d'ordre 1 ou 2 (histogramme, variogramme), mais également des **caractéristiques complexes** du phénomène.

Principe général

On définit une **fonction objectif** O que l'on cherche à minimiser. Cette fonction mesure l'écart entre la réalisation simulée et les propriétés souhaitées. Exemple classique :

$$O = \sum_h [\gamma_{\text{sim}}(h) - \gamma_{\text{théo}}(h)]^2 + \alpha \sum_z [f_{\text{sim}}(z) - f_{\text{cible}}(z)]^2 \quad (23)$$

où γ désigne le variogramme, f l'histogramme, et α un poids de pondération.

La fonction objectif peut inclure : - Courbes tonnage-teneur (contexte minier) - Relations déterministes entre variables - Contraintes géologiques (structures, contacts) - Statistiques d'ordre supérieur (connectivité, proportions, asymétries spatiales)

Algorithme

1. Initialisation :

- Tirer aléatoirement une valeur pour chaque point à simuler en respectant l'histogramme désiré
- Placer les valeurs conditionnantes (points observés) dans le champ
- Calculer le variogramme expérimental et évaluer O_0

2. Itération ($i = 1, 2, \dots$) :

- a) Tirer au hasard un point du champ :
 - Si c'est un point conditionnant $\rightarrow$ ne rien changer
 - Sinon $\rightarrow$ tirer une nouvelle valeur z' selon la distribution cible
- b) Calculer la nouvelle fonction objectif O_{i+1}
- c) Décider d'accepter ou non selon la règle de Metropolis :

$$p_{\text{accept}} = \exp\left(-\frac{O_{i+1} - O_i}{T}\right) \quad (24)$$

où T est la « température » :

- Si $O_{i+1} < O_i \rightarrow$ accepter toujours (amélioration)
 - Sinon $\rightarrow$ accepter avec probabilité p_{accept}
3. **Refroidissement** : La température T diminue lentement selon un schéma défini (par exemple $T_{i+1} = \alpha T_i$ avec $\alpha \approx 0.95$). Cela permet :
- En début : explorer largement l'espace des solutions (échapper aux minima locaux)
 - En fin : converger vers un optimum global
4. **Critère d'arrêt** : Arrêter lorsque $O < O_{\text{seuil}}$ ou après un nombre maximal d'itérations.

Remarques

Initialisation : Il est avantageux d'amorcer le recuit simulé avec une réalisation SGS ou matricielle plutôt qu'avec un champ entièrement aléatoire. Cela accélère la convergence.

Flexibilité : La fonction objectif peut être enrichie très facilement pour intégrer des contraintes spécifiques (géologiques, géométriques, statistiques).

Coût computationnel : Le recuit simulé est généralement **plus coûteux** que les méthodes matricielles ou SGS, car il explore un grand nombre de configurations avant d'accepter une solution satisfaisante. Il est donc réservé aux cas où les méthodes classiques ne peuvent satisfaire simultanément toutes les contraintes.

Usage : Méthode de dernier recours lorsque aucune méthode standard ne permet de respecter toutes les contraintes imposées.

La méthode SGS construit la réalisation conditionnelle progressivement, point par point, en intégrant chaque nouvelle valeur simulée comme donnée conditionnante pour les suivantes — contrairement au post-conditionnement par krigeage (section suivante), qui rend conditionnel en une seule fois un champ déjà entièrement simulé.

Atelier interactif 12.2 — Animation SGS

Cet atelier interactif est disponible uniquement dans la version web du chapitre.

4 Post-conditionnement par krigeage

Certaines méthodes de simulation ne permettent pas de générer directement des réalisations conditionnelles, c'est-à-dire des champs simulés qui honorent exactement les valeurs observées aux points d'échantillonnage. Afin de pallier cette limitation, on recourt à une technique appelée post-conditionnement par krigeage.

Cette approche consiste à transformer une réalisation non conditionnelle en y ajoutant un terme correctif obtenu par krigeage des résidus entre les données observées et les valeurs simulées aux points d'échantillonnage. Le champ ainsi ajusté respecte exactement les données mesurées tout en préservant, autant que possible, les caractéristiques spatiales et statistiques de la réalisation initiale.

4.1 Principe du post-conditionnement par krigeage

On suppose que la variable régionalisée $Z(\mathbf{x})$ suit une distribution gaussienne de moyenne nulle. La démarche se décompose en trois étapes :

1. Simulation non conditionnelle

On génère une réalisation non conditionnelle $Z_{nc}(\mathbf{x})$ sur l'ensemble du domaine d'étude, incluant à la fois :

- les points de prédiction où l'on souhaite simuler la variable ;
- les points d'échantillonnage $\mathbf{x}_i$ où des observations sont disponibles.

On note $Z_{nc}(\mathbf{x}_i)$ les valeurs simulées aux points d'observation, qui ne coïncident généralement pas avec les données réelles $Z_{obs}(\mathbf{x}_i)$.

2. Krigeage des données observées et simulées

On effectue ensuite un krigeage (simple ou ordinaire) sur l'ensemble du domaine en utilisant deux jeux de données distincts :

- $Z_{kr,obs}(\mathbf{x})$: estimation par krigeage à partir des données observées $Z_{obs}(\mathbf{x}_i)$;
- $Z_{kr,nc}(\mathbf{x})$: estimation par krigeage à partir des valeurs simulées non conditionnelles aux points d'observation $Z_{nc}(\mathbf{x}_i)$.

Ces deux champs krigés permettent de quantifier l'écart entre ce qui devrait être observé (selon les données réelles) et ce qui est effectivement simulé.

3. Calcul de la simulation conditionnelle par correction additive

La simulation conditionnelle s'obtient en corrigeant la réalisation non conditionnelle par l'ajout d'un terme de correction :

$$Z_{cond}(\mathbf{x}) = Z_{nc}(\mathbf{x}) + [Z_{kr,obs}(\mathbf{x}) - Z_{kr,nc}(\mathbf{x})] \quad (25)$$

où :

- $Z_{cond}(\mathbf{x})$ est la simulation conditionnelle post-conditionnée ;
- $Z_{nc}(\mathbf{x})$ est la réalisation non conditionnelle initiale ;
- $Z_{kr,obs}(\mathbf{x})$ est l'estimation par krigeage des observations réelles ;
- $Z_{kr,nc}(\mathbf{x})$ est l'estimation par krigeage de la simulation non conditionnelle.

Le terme correctif $[Z_{kr,obs}(\mathbf{x}) - Z_{kr,nc}(\mathbf{x})]$ représente l'erreur de conditionnement qu'il faut ajouter à la simulation pour qu'elle honore exactement les données. Le résultat $Z_{cond}(\mathbf{x})$ reproduit alors fidèlement les valeurs observées tout en préservant la structure de corrélation spatiale de la simulation initiale.

La Figure 2 illustre le principe du post-conditionnement par krigeage. On y observe que pour rendre conditionnelle une simulation initialement non conditionnelle, il suffit de lui additionner l'erreur de krigeage entre les observations et la simulation, ce qui force la réalisation à respecter exactement les valeurs échantillonnées.




FIGURE 2 : Principe du post-conditionnement par krigeage.

4.2 Propriétés mathématiques

— Exactitude aux points d'observation :

Si un point $\mathbf{x}_0$ coïncide avec un point d'observation $\mathbf{x}_i$, alors le krigeage interpolant exactement les données, on a :

$$Z_{kr,obs}(\mathbf{x}_i) = Z_{obs}(\mathbf{x}_i) \quad \text{et} \quad Z_{kr,nc}(\mathbf{x}_i) = Z_{nc}(\mathbf{x}_i) \quad (26)$$

Par conséquent :

$$Z_{cond}(\mathbf{x}_i) = Z_{nc}(\mathbf{x}_i) + [Z_{obs}(\mathbf{x}_i) - Z_{nc}(\mathbf{x}_i)] = Z_{obs}(\mathbf{x}_i) \quad (27)$$

La simulation post-conditionnée reproduit donc parfaitement les valeurs observées aux points d'échantillonnage.

À l'inverse, loin de tous les points d'observation, l'influence du krigeage s'estompe et les deux estimations krigées tendent vers la moyenne (nulle dans notre cas), de sorte que :

$$Z_{kr,obs}(\mathbf{x}) \approx Z_{kr,nc}(\mathbf{x}) \approx 0 \quad \Rightarrow \quad Z_{cond}(\mathbf{x}) \approx Z_{nc}(\mathbf{x}) \quad (28)$$

La simulation conditionnée retrouve alors la structure de la simulation non conditionnelle initiale dans les zones non informées.

— Variance de l'erreur de conditionnement :

On peut démontrer que la variance de l'erreur entre la simulation conditionnelle et la vraie valeur (inconnue) de la variable régionalisée vérifie :

$$\text{Var} [Z_{\text{cond}}(\mathbf{x}) - Z(\mathbf{x})] = 2\sigma_{\text{SK}}^2(\mathbf{x}) \quad (29)$$

où $\sigma_{\text{SK}}^2(\mathbf{x})$ désigne la variance de krigeage simple au point $\mathbf{x}$.

Cette relation indique qu'une seule réalisation conditionnelle issue du post-conditionnement présente une variance d'erreur deux fois supérieure à celle d'un estimateur par krigeage simple.

Il ne faut donc jamais utiliser une seule simulation post-conditionnée comme estimateur ponctuel : l'incertitude associée serait sous-estimée.

— **Convergence de la moyenne des simulations conditionnelles** :

Si l'on génère un ensemble de S simulations conditionnelles indépendantes $\{Z_{\text{cond}}^{(s)}(\mathbf{x})\}_{s=1}^S$ et que l'on calcule leur moyenne :

$$\bar{Z}_{\text{cond}}(\mathbf{x}) = \frac{1}{S} \sum_{s=1}^S Z_{\text{cond}}^{(s)}(\mathbf{x}) \quad (30)$$

alors, lorsque $S \rightarrow \infty$:

$$\bar{Z}_{\text{cond}}(\mathbf{x}) \xrightarrow{S \rightarrow \infty} Z_{\text{SK}}(\mathbf{x}) \quad (31)$$

où $Z_{\text{SK}}(\mathbf{x})$ est l'estimateur de krigeage simple. De plus, la variance d'estimation de cette moyenne converge vers la variance de krigeage simple :

$$\text{Var} [\bar{Z}_{\text{cond}}(\mathbf{x})] \xrightarrow{S \rightarrow \infty} \sigma_{\text{SK}}^2(\mathbf{x}) \quad (32)$$

et la dispersion des réalisations individuelles autour de cette moyenne (variance inter-réalisations) est également égale à $\sigma_{\text{SK}}^2(\mathbf{x})$.

Le post-conditionnement permet donc, après moyennage d'un nombre suffisant de réalisations, de reconstituer à la fois l'estimation optimale (krigeage simple) et l'incertitude associée (variance de krigeage), tout en fournissant des réalisations qui respectent la variabilité spatiale naturelle du phénomène étudié.

5 Propriétés des simulations

La Figure 3 illustre quelques propriétés des simulations conditionnelles et non conditionnelles, en mettant en évidence leurs différences de comportement et leurs relations avec les observations.

Une simulation non conditionnelle $Z_s(\mathbf{x})$ possède une espérance constante égale à la moyenne globale du modèle (m), ce qui reflète l'absence totale d'information spatiale. Une simulation conditionnelle $Z_{sc}(\mathbf{x})$, en revanche, voit son espérance converger vers l'estimateur de krigeage simple $Z^*(\mathbf{x})$: dans ce cas, l'espérance varie spatialement en fonction de la proximité et de la configuration des observations, ce qui capture la structure d'information locale. Aux points d'observation, Z^* reproduit exactement les valeurs mesurées, tandis que loin de toute donnée, elle tend vers la moyenne m , rejoignant asymptotiquement le comportement non conditionnel.

La variance spatiale est l'autre point de contraste entre les deux approches. Une simulation non conditionnelle conserve intégralement la variance *a priori* du phénomène (σ^2), car aucune information ne vient contraindre la variabilité du champ. Le conditionnement aux observations réduit au contraire

Non-conditionnelle	Conditionnelle
$E[Z_s] = m$	$E[Z_{sc}] = Z^*$
$Var(Z_s) = \sigma^2$	$Var(Z_{sc}) = \sigma_{KS}^2$
$Var(Z - Z_s) = 2\sigma^2$	$Var(Z - Z_{sc}) = 2\sigma_{KS}^2$

FIGURE 3 : Propriétés des simulations conditionnelles et non conditionnelles.

cette variance à σ_{SK}^2 , la variance de krigeage simple, qui quantifie l'incertitude résiduelle après prise en compte des données. Cette réduction est maximale aux points d'observation (où $\sigma_{SK}^2 = 0$) et s'atténue progressivement avec la distance, jusqu'à retrouver la variance globale σ^2 dans les zones non informées. Le rapport σ_{SK}^2/σ^2 mesure ainsi la proportion d'incertitude non résolue par les observations : plus ce rapport est faible, plus le conditionnement est informatif.

L'erreur de prédiction — c'est-à-dire l'écart entre la vraie valeur inconnue $Z(\mathbf{x})$ et la valeur simulée — présente elle aussi une structure remarquable dans les deux cas. Pour une simulation non conditionnelle, la variance de cette erreur vaut $2\sigma^2$, soit exactement le double de la variance du champ. Ce résultat s'explique par le fait que Z et Z_s sont deux réalisations indépendantes du même processus stochastique : leur différence a donc une variance égale à la somme de leurs variances individuelles, soit $\sigma^2 + \sigma^2 = 2\sigma^2$. Dans le cas conditionnel, la même logique s'applique, mais avec la variance réduite : $Var(Z - Z_{sc}) = 2\sigma_{SK}^2$. Il s'ensuit qu'une seule réalisation conditionnelle ne doit jamais être utilisée comme estimateur ponctuel, puisque son erreur quadratique moyenne est systématiquement deux fois supérieure à celle du krigeage simple. En revanche, la moyenne d'un grand nombre de simulations conditionnelles converge vers l'estimateur de krigeage, tout en permettant de caractériser l'incertitude globale via la dispersion des réalisations.

Le conditionnement modifie donc les propriétés statistiques des simulations en incorporant l'information des observations. Là où une simulation non conditionnelle reflète uniquement le modèle *a priori* (moyenne m , variance σ^2), une simulation conditionnelle intègre la structure spatiale des données pour produire une espérance variable (le krigeage Z^*) et une variance réduite ($\sigma_{SK}^2 \leq \sigma^2$). Cette réduction de variance ne signifie toutefois pas que les simulations conditionnelles sont des estimateurs plus précis qu'une simple réalisation : leur variance d'erreur reste le double de celle du krigeage. Leur intérêt tient plutôt à leur capacité à générer de multiples scénarios équiprobables qui, collectivement, permettent de quantifier l'incertitude tout en préservant la variabilité spatiale du phénomène — une caractéristique que le krigeage, par son lissage inhérent, ne peut garantir.

Atelier interactif 12.3 — Non conditionnel vs conditionnel

Cet atelier interactif est disponible uniquement dans la version web du chapitre.

La moyenne et la variance ne sont que les deux premiers moments. Le véritable intérêt des simulations apparaît dès qu'on cherche une quantité **non linéaire** de la teneur — un volume au-delà d'un seuil, un tonnage récupérable — que le krigeage, par son lissage, estime mal. Les deux ateliers suivants l'illustrent, sur un site contaminé puis sur un gisement minier.

Atelier interactif 12.4 — Site contaminé : krigeage vs simulations

Cet atelier interactif est disponible uniquement dans la version web du chapitre.

On passe ainsi des propriétés statistiques fondamentales (moyenne, variance, convergence vers le krigeage) à l'exploitation pratique des simulations : quantifier une grandeur non linéaire et son incertitude, là où le krigeage seul échoue. Le même raisonnement gouverne l'estimation des **ressources minières**, où tonnage et métal récupérables au-delà d'une coupure sont aussi des fonctions non linéaires des teneurs.

Atelier interactif 12.5 — Ressources minières : krigeage vs simulations

Cet atelier interactif est disponible uniquement dans la version web du chapitre.

Le krigeage, par son lissage, sous-estime les teneurs élevées et fausse l'évaluation au-delà d'une coupure ; les simulations conditionnelles rétablissent le bilan tonnage-métal et chiffrent le risque associé à la décision d'exploitation.

6 Exercices

6.1 Exercice 1 — Transformation gaussienne (données de Dallas, plomb)

Lorsque la distribution n'est pas normale, on peut transformer la variable $Z(\mathbf{x})$ vers $Y(\mathbf{x})$ qui suit une distribution normale, au moyen de l'anamorphose $Z = \varphi(Y)$. Toutefois la transformation n'assure pas que $Y(\mathbf{x})$ soit multigaussien (p. ex. données de Dallas). Si le champ n'est pas gaussien, le variogramme de $Z(\mathbf{x})$ ne sera pas reproduit exactement, de même que toutes les covariances et covariances croisées des indicatrices. La transformation gaussienne se fait habituellement sous forme graphique.

La figure ci-dessous présente, pour les données ponctuelles de plomb de Dallas, les fonctions de répartition de $\ln(\text{plomb})$ et d'une $\mathcal{N}(0, 1)$, qui servent de table de correspondance pour l'anamorphose.

(Figure à régénérer — générateur MATLAB dans Examen/CP3/.../11-Simulations.)

- On a observé $Pb = 250$ ppm. Quelle valeur $\mathcal{N}(0, 1)$ doit-on associer à cette valeur de Pb pour la simulation ? Idem pour $Pb = 50$ ppm.
- On a simulé la valeur normale 1,5. Quelle valeur de Pb doit-on associer à cette valeur simulée ? Idem pour $\mathcal{N}(0, 1) = -1$.
- Pour représenter la teneur en plomb d'un bloc de $30 \text{ m} \times 30 \text{ m}$, on simule 25 valeurs normales corrélées sur autant de points d'une grille centrée dans le bloc. Doit-on :

- i. faire la moyenne des valeurs normales et appliquer la transformation inverse à cette moyenne pour obtenir $\ln(Z_v)$ puis évaluer l'exponentielle, ou
- ii. transformer chaque valeur normale en $\ln(\text{plomb})$ et faire la moyenne des 25 valeurs avant de prendre l'exponentielle, ou
- iii. transformer chaque valeur ponctuelle vers $\ln(\text{plomb})$, évaluer l'exponentielle pour chaque valeur séparément et faire la moyenne des 25 valeurs de plomb obtenues ?

Pourquoi ?

- d) On obtient les valeurs normales simulées $(-2, -1,5, -1)$. Calculez les valeurs de plomb correspondantes et l'écart-type de ces valeurs de plomb. Faites la même chose avec les valeurs normales $(1, 1,5, 2)$. Que peut-on conclure ?

i Solution

- a) Par lecture graphique de la transformation : $\text{Pb} = 250 \Rightarrow y = 0,54$; $\text{Pb} = 50 \Rightarrow y = -1,24$.
- b) $y = 1,5 \Rightarrow \text{Pb} = 810$; $y = -1 \Rightarrow \text{Pb} = 59$.
- c) La réponse est (iii). Physiquement, la teneur d'un bloc est la moyenne des teneurs ponctuelles dans le bloc. Comme les transformations impliquées sont non linéaires, il faut appliquer les transformations aux teneurs ponctuelles (ainsi le log d'une moyenne de valeurs n'est pas la moyenne des log des valeurs ; ici on veut bien la moyenne arithmétique des teneurs ponctuelles, donc on transforme chaque valeur normale vers le plomb avant de moyenner).
- d) Les valeurs normales $(-2, -1,5, -1)$ donnent les teneurs $(27, 40,5, 59)$, dont l'écart-type (division par $n-1$) vaut 16,1, alors que $(1, 1,5, 2)$ donnent $(486, 810, 2459)$, dont l'écart-type vaut 1076. On voit donc que l'écart-type dépend des teneurs, contrairement à l'écart-type de krigeage σ_{SK} et similairement à l'écart-type conditionnel calculé par krigeage d'indicateurs.

6.2 Exercice 2 — Recuit simulé

À l'itération « n » de l'algorithme du recuit simulé, on a $O_n = 100$. Le paramètre de température vaut $T = 10$. Le critère de Metropolis accepte une perturbation candidate qui augmente la fonction objectif avec la probabilité $\mathbb{P} = \exp(-\Delta O/T)$ (et l'accepte toujours si elle la diminue). Déterminez si l'on doit accepter la perturbation candidate dans chacun des cas suivants, où rand est un nombre aléatoire tiré d'une loi $\mathcal{U}(0, 1)$:

- a) $O_{\text{candidat}} = 95$ et $\text{rand} = 0,67$;
- b) $O_{\text{candidat}} = 105$ et $\text{rand} = 0,67$;
- c) $O_{\text{candidat}} = 105$ et $\text{rand} = 0,43$;
- d) $O_{\text{candidat}} = 105$, $\text{rand} = 0,43$ mais T vaut 5 plutôt que 10.
- e) En comparant c) et d), comment se comporte l'algorithme au fur et à mesure que l'on décroît le paramètre de température T ?

i Solution

- a) O décroît ($95 < 100$) : on accepte toujours la modification.
- b) $\Delta O = 105 - 100 = 5$. On accepte avec probabilité $\exp(-5/10) = 0,606$. Comme $\text{rand} = 0,67 > 0,606$, on **refuse** la modification.
- c) Même probabilité d'acceptation 0,606. Comme $\text{rand} = 0,43 < 0,606$, on **accepte** la modification proposée.
- d) On accepte avec probabilité $\exp(-5/5) = \exp(-1) = 0,368$. Comme $\text{rand} = 0,43 > 0,368$,

on **refuse** la modification.

e) Il devient de plus en plus difficile d'accepter une modification qui augmente la fonction objectif O au fur et à mesure que l'on diminue T .

6.3 Exercice 3 — Contraintes minières

Lorsque l'on exploite des blocs dans une mine ou lorsque l'on décontamine un site, on n'opère pour ainsi dire jamais librement sur chaque bloc séparément : l'ordre dans lequel apparaissent les teneurs est habituellement très important. Pour accéder à un bloc, on doit miner les blocs qui le précèdent (selon la direction du minage indiquée). Si un bloc est miné, on peut ou non le traiter.

Le coût de minage est 0,5 et le coût de traitement est 2,6. On considère les quatre scénarios de teneurs de blocs suivants (la colonne A est minée en premier, puis B, puis C) :

Bloc	Scénario a)	Scénario b)	Scénario c)	Scénario d)
A	4	2	2	3
B	2	4	3	4
C	3	3	4	2

- Calculez le tonnage de minerai, la teneur moyenne du minerai, le tonnage de stérile qui doit être miné et le profit de chaque scénario **sous la contrainte minière**, et comparez avec les mêmes quantités en **sélection libre**.
- Dans les scénarios a) à d), le tonnage de minerai est égal ou supérieur à celui obtenu par sélection libre. Illustrez un scénario de teneurs de blocs où le tonnage de minerai est inférieur (conservez les mêmes coûts).
- Dans les scénarios a) à d), la teneur du minerai est égale ou inférieure à celle obtenue par sélection libre. Illustrez un scénario de coûts et de teneurs de blocs où la teneur du minerai est supérieure à celle obtenue par sélection libre.
- Est-il possible d'avoir un profit sous contrainte minière qui soit supérieur à celui obtenu par sélection libre ?

i Solution

a) Sélection libre (référence) : on mine seulement le bloc de teneur 4 : tonnage de minerai = 1, teneur moyenne = 4, profit = $4 - 2,6 - 0,5 = 0,9$.

— **Scénario a)** : identique à la sélection libre.

— **Scénario b)** : on mine A et B, mais seul B est traité. Tonnage de minerai 1, teneur moyenne 4, profit $4 - 2 \times 0,5 - 2,6 = 0,4$, tonnage de stérile 1.

— **Scénario c)** : on mine A, B et C ; on traite B et C. Tonnage de minerai 2, teneur moyenne 3,5, profit $(4 + 3) - 3 \times 0,5 - 2 \times 2,6 = 0,3$, tonnage de stérile 1. Noter que l'on doit traiter B même si sa valeur nette est $3 - 0,5 - 2,6 = -0,1$: si on ne le traite pas, on aura un profit de $4 - 3 \times 0,5 - 2,6 = -0,1$.

— **Scénario d)** : on mine et on traite A et B. Tonnage de minerai 2, teneur moyenne 3,5, profit $(4 + 3) - 2 \times 0,5 - 2 \times 2,6 = 0,8$, tonnage de stérile 0.

b) Avec A, B, C = 2, 3, 3,5 : on ne mine alors aucun bloc (aucune séquence ne devient rentable sous contrainte), alors que la sélection libre minerait le bloc de teneur 3,5.

c) Avec A, B, C = 4, 2, 3,2 : la sélection libre prend 4 et 3,2, dont la teneur moyenne est 3,6, alors que la sélection sous contrainte ne prend que 4 (teneur du minerai = $4 > 3,6$).

d) Non, c'est impossible. C'est la seule fonction qui a un comportement entièrement prévisible en lien avec les contraintes minières : plus celles-ci sont sévères, plus il y a perte de profits.

6.4 Exercice 4 — Simulation séquentielle gaussienne

La figure ci-dessous montre les fonctions de répartition d'une $\mathcal{N}(0, 1)$ et du $\ln(\text{Pb})$ obtenu à partir d'échantillons d'un champ de contamination au plomb. Elle sert de table d'anamorphose $Z = \varphi(Y)$.

(Figure à régénérer — générateur MATLAB dans Examen/CP3/.../11-Simulations.)

- a) On a observé trois données aux localisations $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$, avec les teneurs en Pb indiquées. Complétez le tableau ci-dessous en convertissant chaque teneur en sa valeur gaussienne Y par lecture de la transformation.

Donnée	$\mathbf{x}_1$	$\mathbf{x}_2$	$\mathbf{x}_3$
Pb (ppm)	...	...	...
$Y = \varphi^{-1}(Z)$	?	?	?

La variable gaussienne $Y(\mathbf{x})$ associée aux teneurs de Pb présente un variogramme sphérique isotrope de portée 400 m, avec $C_0 = 0$ et $C = 1$.

- b) Quelles sont les unités de C_0 et de C ?

On effectue le krigeage simple de Y au point $\mathbf{x}_0$ et l'on obtient le système de krigeage donnant les poids λ .

- c) Quelles seront la valeur krigée $Y^*(\mathbf{x}_0)$ et la variance de krigeage simple σ_{SK}^2 en ce point $\mathbf{x}_0$? (Si vous n'avez pas répondu à la question a), posez respectivement les valeurs normales 0,25, -0,75, 0,5 pour les données 1, 2 et 3.)
- d) On tire d'une distribution $\mathcal{U}(0, 1)$ la valeur 0,7. Quelle est la valeur gaussienne simulée à ce point ?
- e) Quelle est la concentration de plomb que l'on simule à ce point ? (Posez la valeur gaussienne simulée à 1,4 si vous n'avez pas pu répondre à d).)

i Solution

b) C_0 et C sont les composantes du variogramme de la variable gaussienne Y , dont la variance est unitaire : ils n'ont **aucune unité**.

c) La valeur krigée est $Y^*(\mathbf{x}_0) = \sum_i \lambda_i Y_i$ (les poids λ_i sont fournis par la résolution du système de krigeage simple), et la variance de krigeage simple est $\sigma_{SK}^2 = C(0) - \sum_i \lambda_i C(\mathbf{x}_0 - \mathbf{x}_i)$.

d) On simule la valeur gaussienne par $Y^{(s)}(\mathbf{x}_0) = Y^*(\mathbf{x}_0) + \sigma_{SK} \Phi^{-1}(0,7)$. Par lecture de la table de la loi normale, $\Phi^{-1}(0,7) \approx 0,5244$.

e) On convertit la valeur gaussienne simulée vers le plomb par anamorphose inverse $Z = \varphi(Y)$. Par lecture graphique, avec une valeur gaussienne simulée d'environ 1,4, on lit $\ln(\text{Pb}) \approx 6$, soit une concentration de plomb de $e^6 \approx 403,42$ ppm.

6.5 Exercice 5 — Propriétés des simulations (non conditionnelles vs conditionnelles)

Pour chacune des questions a) à f), écrivez **uniquement**, sous forme mathématique, la propriété en jeu (à la manière d'un exemple : « la moyenne des valeurs simulées vaut m »).

Pour a) à d), on a un champ en 2D de taille G pour lequel on génère un très grand nombre S de **simulations non conditionnelles** $Z^{(s)}(\mathbf{x})$ sur une grille serrée de points. Les simulations sont effectuées avec moyenne théorique m et variance théorique σ^2 .

- On se place à un point donné $\mathbf{x}_0$ et on examine les valeurs obtenues pour les différentes réalisations. Quelles sont la moyenne et la variance des valeurs simulées à ce point ?
- Pour la 1^{re} réalisation, on calcule la variance expérimentale sur l'ensemble du domaine. On répète l'exercice pour la 2^e réalisation, la 3^e et ainsi de suite. Que vaut la moyenne (calculée sur l'ensemble des réalisations) des variances expérimentales obtenues pour chaque réalisation ?
- Pour chaque réalisation, on regroupe les valeurs en blocs de taille V (c.-à-d. on calcule la moyenne des valeurs à l'intérieur du bloc). Pour un bloc donné, quelles seront la moyenne et la variance des teneurs de ce bloc sur l'ensemble des réalisations ?
- Pour la 1^{re} réalisation, on calcule la variance expérimentale des teneurs des blocs de taille V sur l'ensemble du domaine de taille G . On répète l'exercice pour chaque réalisation. Que vaut la moyenne des variances expérimentales ainsi obtenues ?

Pour e) et f), on considère cette fois un très grand nombre de **simulations conditionnelles** sur une grille de points très serrée, toujours sur un champ en 2D de taille G .

- On se place à un point donné $\mathbf{x}_0$ et on examine les valeurs obtenues pour les différentes réalisations. Quelles sont la moyenne et la variance des valeurs simulées à ce point ?
- Pour chaque réalisation, on regroupe les valeurs simulées en blocs de taille V . Pour un bloc donné, quelles seront la moyenne et la variance des teneurs de ce bloc sur l'ensemble des réalisations ?

i Solution

- Moyenne m et variance σ^2 .
- $D^2(\cdot | G)$: la variance de dispersion des points dans le domaine G .
- Moyenne m et variance $D^2(V | G)$: la variance de dispersion des blocs de taille V dans G .
- $D^2(V | G)$.
- La valeur obtenue par krigeage simple, $Z_{SK}^*(\mathbf{x}_0)$, et la variance de krigeage simple $\sigma_{SK}^2(\mathbf{x}_0)$.
- La valeur obtenue par krigeage simple de bloc, $Z_{SK}^*(V)$, et la variance de krigeage simple de bloc $\sigma_{SK}^2(V)$.

6.6 Exercice 6 — Post-conditionnement par krigeage simple

Le tableau suivant présente 20 valeurs simulées (non conditionnellement) d'une v.a. suivant un vario-gramme sphérique avec $C = 10$, $a = 30$, aux coordonnées $x = 1$ à $x = 20$. Des données ont été observées aux points x_5 , x_{10} et x_{20} .

x	$Z(x)$	$Z^*(x)$	$Z^{(s)}(x)$	$Z^{(s)*}(x)$	$Z_c^{(s)*}(x)$
1	—	0,23	−3,55	−1,19	
2	—	0,18	−2,74	−1,25	
3	—	0,14	−1,64	−1,29	
4	—	0,08	−1,89	−1,33	
5	0,02	0,02	−1,37	−1,37	
6	—	−0,08	−1,74	−1,66	
7	—	−0,19	−3,16	−1,94	
8	—	−0,30	−3,39	−2,21	
9	—	−0,41	−3,51	−2,48	
10	−0,53	−0,53	−2,74	−2,74	
11	—	−0,75	−3,60	−2,26	
12	—	−0,97	−2,80	−1,77	
13	—	−1,20	−1,39	−1,27	
14	—	−1,42	−0,33	−0,77	
15	—	−1,65	−1,05	−0,27	
16	—	−1,88	−0,04	0,23	
17	—	−2,11	0,25	0,74	
18	—	−2,34	1,23	1,24	
19	—	−2,57	2,53	1,74	
20	−2,80	−2,80	2,24	2,24	

Ici $Z^*(x)$ est le krigeage simple des données observées, $Z^{(s)}(x)$ la simulation non conditionnelle, et $Z^{(s)*}(x)$ le krigeage simple des valeurs simulées aux points de donnée.

- Complétez la dernière colonne du tableau donnant, aux points 1 à 20, les valeurs simulées **conditionnellement** aux données observées en x_5 , x_{10} et x_{20} .
- Démontrez que si l'on estime la teneur d'un point par une simulation conditionnelle en ce point, la variance théorique de l'erreur est le double de celle d'un krigeage simple.

i Solution

a) On applique la formule de post-conditionnement

$$Z_c^{(s)}(x) = Z^*(x) + (Z^{(s)}(x) - Z^{(s)*}(x)),$$

c'est-à-dire que l'on ajoute au krigeage des données réelles l'écart de simulation (simulation non conditionnelle moins son propre krigeage). On obtient ainsi un champ qui honore exactement les valeurs observées en x_5 , x_{10} et x_{20} .

b) En notant $Z_c^{(s)}$ la simulation conditionnelle, l'erreur d'estimation au point x s'écrit

$$Z(x) - Z_c^{(s)}(x) = \{Z(x) - Z^*(x)\} - \{Z^{(s)}(x) - Z^{(s)*}(x)\}.$$

La covariance entre l'erreur réelle $\{Z(x) - Z^*(x)\}$ et l'erreur simulée $\{Z^{(s)}(x) - Z^{(s)*}(x)\}$ est nulle (les deux champs sont indépendants mais partagent la même structure). Par conséquent

$$\text{Var}(Z(x) - Z_c^{(s)}(x)) = \sigma_{SK}^2 + \sigma_{SK}^2 = 2\sigma_{SK}^2,$$

soit le double de la variance de krigeage simple.

6.7 Exercice 7 — Décomposition de Cholesky (méthode LU)

On simule une variable Z à 4 emplacements à l'aide de la décomposition de Cholesky. Les emplacements sont placés dans l'ordre 1, 2, 3, 4 dans la matrice de covariance $\mathbf{K}$. La factorisation $\mathbf{K} = \mathbf{L}\mathbf{L}^\top$ donne la matrice triangulaire inférieure $\mathbf{L}$ suivante :

(Matrice $\mathbf{L}$ à régénérer — générateur MATLAB dans Examen/CP3/.../11-Simulations.)

- Quelle est la variance du processus stochastique Z ?
- Quelle est la covariance entre Z_3 et Z_4 ?
- On a observé Z_1 et Z_2 . Déterminez les valeurs de Y_1 et Y_2 qui permettent d'assurer un conditionnement exact par la méthode de Cholesky.
- Quelle est l'espérance conditionnelle de Z_3 sachant Z_1 et Z_2 ? (Posez Y_1 et Y_2 si vous n'avez pas répondu à la question c.)
- Quelle est la covariance conditionnelle entre Z_3 et Z_4 ?
- On a généré le vecteur aléatoire $\mathbf{Y} = [Y_3 \ Y_4]^\top$. Que vaut Z_4 (conditionnelle à Z_1 et Z_2) ? (Posez Y_3 et Y_4 si vous n'avez pas répondu à la question c.)

i Solution

Le vecteur simulé est $\mathbf{Z} = \mathbf{L}\mathbf{Y}$, où $\mathbf{Y} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ et $\mathbf{L}$ est triangulaire inférieure. En écrivant ligne par ligne, $Z_i = \sum_{j \leq i} L_{ij} Y_j$.

a) La variance vaut $\text{Var}(Z_i) = \sum_{j \leq i} L_{ij}^2 = (\mathbf{L}\mathbf{L}^\top)_{ii} = K_{ii}$: c'est le terme diagonal de $\mathbf{K}$ (palier), identique pour tous les emplacements en stationnarité du second ordre.

b) $\text{Cov}(Z_3, Z_4) = \sum_j L_{3j} L_{4j} = (\mathbf{L}\mathbf{L}^\top)_{34} = K_{34}$.

c) Le conditionnement exact par LU s'obtient en résolvant, pour les emplacements observés, le système triangulaire $\mathbf{L}_{\text{obs}} \mathbf{Y}_{\text{obs}} = \mathbf{Z}_{\text{obs}}$. Comme $\mathbf{L}$ est triangulaire inférieure, on procède par substitution avant :

$$Y_1 = \frac{Z_1}{L_{11}}, \quad Y_2 = \frac{Z_2 - L_{21}Y_1}{L_{22}}.$$

Ces Y_1, Y_2 remplacent les composantes aléatoires correspondantes pour forcer la réalisation à honorer Z_1 et Z_2 .

d) L'espérance conditionnelle s'obtient en gardant les Y conditionnés (Y_1, Y_2) et en annulant les composantes aléatoires restantes ($\mathbb{E}[Y_3] = \mathbb{E}[Y_4] = 0$) :

$$\mathbb{E}[Z_3 \mid Z_1, Z_2] = L_{31}Y_1 + L_{32}Y_2.$$

e) La covariance conditionnelle ne fait intervenir que les composantes aléatoires non conditionnées (Y_3, Y_4 , de variance 1 et indépendantes) :

$$\text{Cov}(Z_3, Z_4 \mid Z_1, Z_2) = L_{33}L_{43}.$$

(seul le produit des coefficients sur les colonnes encore aléatoires subsiste ; les colonnes 1 et 2, devenues déterministes, n'y contribuent plus.)

f) En conditionnant à Z_1, Z_2 et en injectant le vecteur aléatoire généré $\mathbf{Y} = [Y_3 \ Y_4]^\top$:

$$Z_4 = L_{41}Y_1 + L_{42}Y_2 + L_{43}Y_3 + L_{44}Y_4,$$

où Y_1, Y_2 proviennent du conditionnement (question c) et Y_3, Y_4 du tirage.

6.8 Exercice 8 — Étude de cas : arsenic autour d'une fonderie

Exercice de synthèse — mobilise aussi le krigeage d'indicatrices (ch. 11) et le cokrigeage (ch. 10).

Vous devez appuyer une équipe d'ingénierie environnementale dans l'évaluation du risque lié à la présence d'arsenic (As) autour d'une fonderie en activité. Selon les normes en vigueur, toute zone dont la concentration en As dépasse 50 ppm est considérée comme contaminée (critère C du *Guide d'intervention — Protection des sols et réhabilitation des terrains contaminés*).

Une campagne d'échantillonnage a mesuré les concentrations d'As dans 148 forages environnementaux répartis de manière non uniforme autour de la zone d'étude. Les résultats montrent une forte hétérogénéité spatiale, avec plusieurs valeurs élevées à proximité de la fonderie. On vous demande de :

- cartographier la probabilité $\mathbb{P}(\text{As}(\mathbf{x}) > 50 \text{ ppm})$ en tout point du domaine ;
 - fournir une estimation de la proportion totale de la surface où le seuil de 50 ppm est dépassé, accompagnée d'une mesure d'incertitude conditionnelle (p. ex. un intervalle de confiance à 95 %).
- a) Proposez une méthodologie, basée sur les outils géostatistiques vus en classe, qui permet de répondre à ces questions. Répondez par une liste à puces.

Par ailleurs, la concentration en cuivre (Cu) a aussi été caractérisée en 248 localisations (148 colocalisées avec l'As), et l'on observe une forte corrélation spatiale et statistique entre Cu et As.

- b) Comment modifieriez-vous votre algorithme ou votre démarche pour tenir compte de cette variable secondaire (Cu) lors de l'estimation des probabilités de dépassement et de l'incertitude associée ? Modifiez seulement les puces de la question a).

i Solution

a) Deux familles de méthodologies répondent au problème.

Par simulations géostatistiques :

1. **Transformer les données** vers une variable (quasi) gaussienne, p. ex. par anamorphose graphique $Z = \varphi(Y)$ (transformation log ou normal-score).
2. **Modéliser le variogramme** de la variable transformée : variogramme expérimental puis ajustement d'un modèle (p. ex. sphérique).
3. **Simuler** plusieurs réalisations conditionnelles (p. ex. $S = 100$) par simulation séquentielle gaussienne (SGS) ou par Cholesky (LU). Chaque réalisation $Z^{(s)}(\mathbf{x})$ est un scénario possible du champ d'As.
4. **Transformation inverse** de chaque réalisation vers l'espace original ($Z = \varphi(Y)$).
5. **Carte de probabilité de dépassement** : en chaque point de la grille, compter la proportion de réalisations qui dépassent 50 ppm,

$$\hat{\mathbb{P}}(\text{As}(\mathbf{x}) > 50) = \frac{1}{S} \sum_{s=1}^S \mathbb{1}\{Z^{(s)}(\mathbf{x}) > 50\}.$$

6. **Proportion de surface contaminée** : pour chaque réalisation, calculer la fraction de surface où $\text{As} > 50$, puis moyenner sur les S réalisations ; les percentiles 2,5 % et 97,5 % de cette distribution donnent l'intervalle de confiance à 95 %.

Par krigeage d'indicatrices :

1. **Choisir plusieurs seuils** de teneur (p. ex. 10, 25, 50, 75, 100, 150 ppm), à caler sur l'histogramme des données.
2. **Coder une indicatrice** pour chaque seuil z_k : $i(\mathbf{x}; z_k) = \mathbb{1}\{Z(\mathbf{x}) \leq z_k\}$.
3. **Modéliser un variogramme d'indicatrice** pour chaque seuil (expérimental + modèle théorique).
4. **Kriger l'indicatrice** pour chaque point et chaque seuil, ce qui donne une série de probabilités cumulées.
5. **Reconstruire la CDF locale** : interpoler entre les seuils (en corrigeant les relations d'ordre).
6. **En déduire les quantités demandées** : $\mathbb{P}(As > 50) = 1 - F^*(\mathbf{x}; 50)$; la proportion de surface contaminée est la moyenne spatiale de cette probabilité.
7. **Incertitude** : l'intervalle de confiance à 95 % se lit directement sur la CDF locale (seuils atteignant 2,5 % et 97,5 %).

b) Il suffit d'adapter l'algorithme au cas multivariable en remplaçant les matrices de krigeage par les matrices de **cokrigeage**. Ainsi, pour la voie indicatrice on utilise le **cokrigeage d'indicatrices**, et pour les voies LU et SGS on utilise la **matrice de cokrigeage simple** (la variable secondaire Cu, fortement corrélée et plus densément échantillonnée, améliore l'estimation et resserre l'incertitude).